Extração e Preparação de Dados

Aula 07 – Dados Ausentes: Tratamento Univariado e Multivariado

ibmec

Quem sou eu?

Professor: Luís Aramis dos Reis Pinheiro.

- **Doutorado e Mestrado** em **Ciências Mecânicas** – **UnB** – **CAPES 7**
- **Graduação** em Licenciatura em Física – **UNIFAP**

luis.pinheiro@professores.ibemec.edu.br

(96) 99907-5819

@l_aramis

Dados Ausentes: Tratamento Univariado

- Extração e Preparação de Dados (IBM8915)
- A Decisão Crítica: Descartar ou Preencher?
- 05/03 (Quinta-feira)

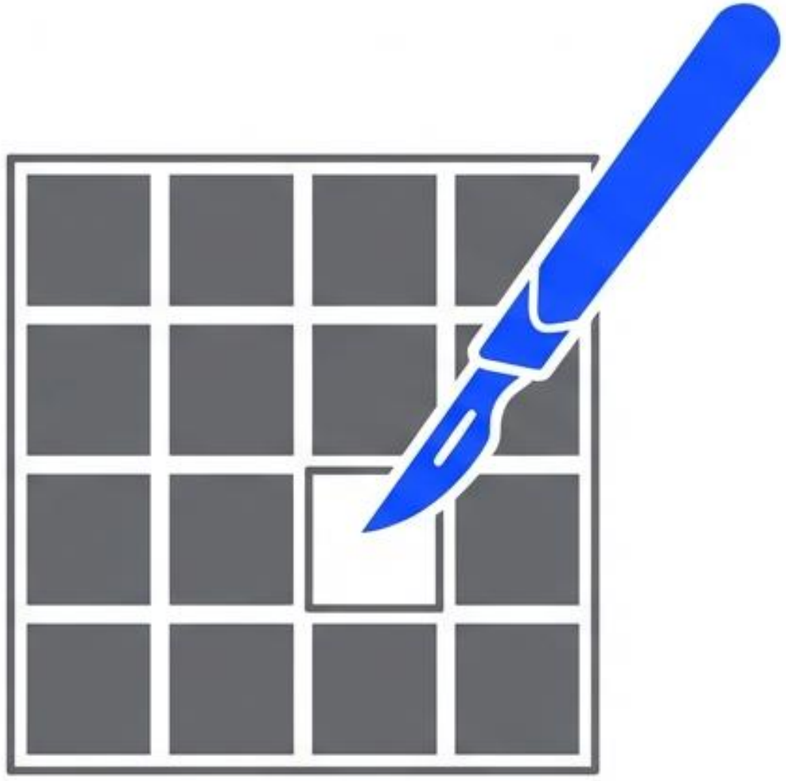

O Dilema do Cirurgião de Dados

A presença de valores nulos (NaN) exige uma escolha analítica binária.

NaN

Caminho A (Exclusão)

Risco de amputar tecido saudável e perder informações valiosas.

Caminho B (Imputação)

Risco de introduzir viés estatístico ao forçar um dado artificial.

- A decisão depende do mecanismo de ausência (MCAR, MAR, MNAR) diagnosticado na Aula 06.

Mecanismo	O que significa?	Estratégia Principal	Risco de Viés
MCAR	Acidente puro.	**Exclusão** (se pouco) ou **Imputação**.	Baixo.
MAR	Explicado por outros dados.	**Imputação Múltipla** (MICE).	Alto se excluir.
MNAR	O valor se esconde.	**Modelagem de Sensibilidade** ou Variável Dummy.	Altíssimo.

A Faca: Exclusão com dropna()

- O método dropna() é a ferramenta de remoção nativa do Pandas.
- **Comportamento Padrão**: Um corte cego. Exclui qualquer linha que contenha pelo menos um valor nulo.
- **Exclusão de Colunas**: Utilizando axis=1, descartamos o atributo inteiro.
- **O Perigo**: Aplicado sem parâmetros, pode dizimar um dataset por causa de poucos valores isolados.

```
df_limpo = df.dropna()
```

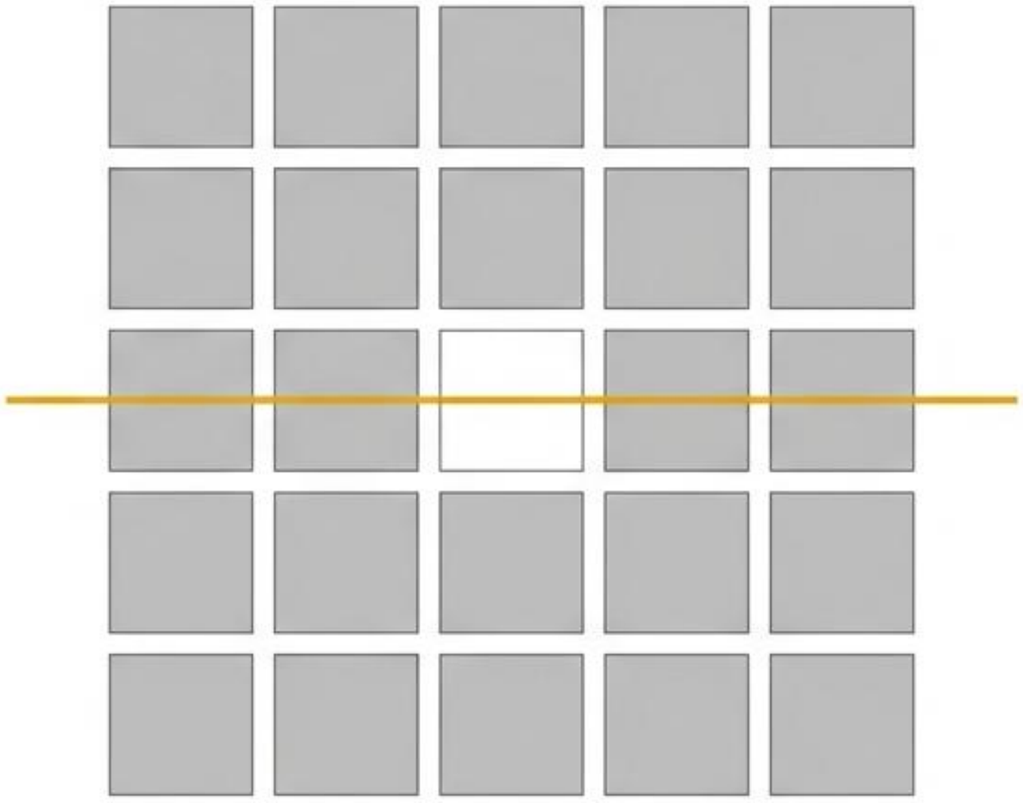

Precisão Cirúrgica: Preservando Dados

```
df.dropna(how='all')
```

Remove a linha apenas se todas as colunas forem nulas (óbito total do registro).

```
df.dropna(thresh=10)
```

Define um limite mínimo de sobrevida. Exige um número específico de colunas preenchidas.

```
df.dropna(subset=['ID_Paciente'])
```

Foca o corte apenas em colunas vitais específicas.

Negligência: O Perigo do Preenchimento Global

- Imputar significa substituir o valor ausente por um dado estimado.
- O método primário é o fillna().
- O Erro Amador: Executar df.fillna(0) em todo o dataset de forma global.
- A Consequência: Corrupção de variáveis categóricas (inserção de zeros em colunas de nomes ou textos).

~~df.fillna(0)~~

ID	Nome	Idade
001	**0**	30

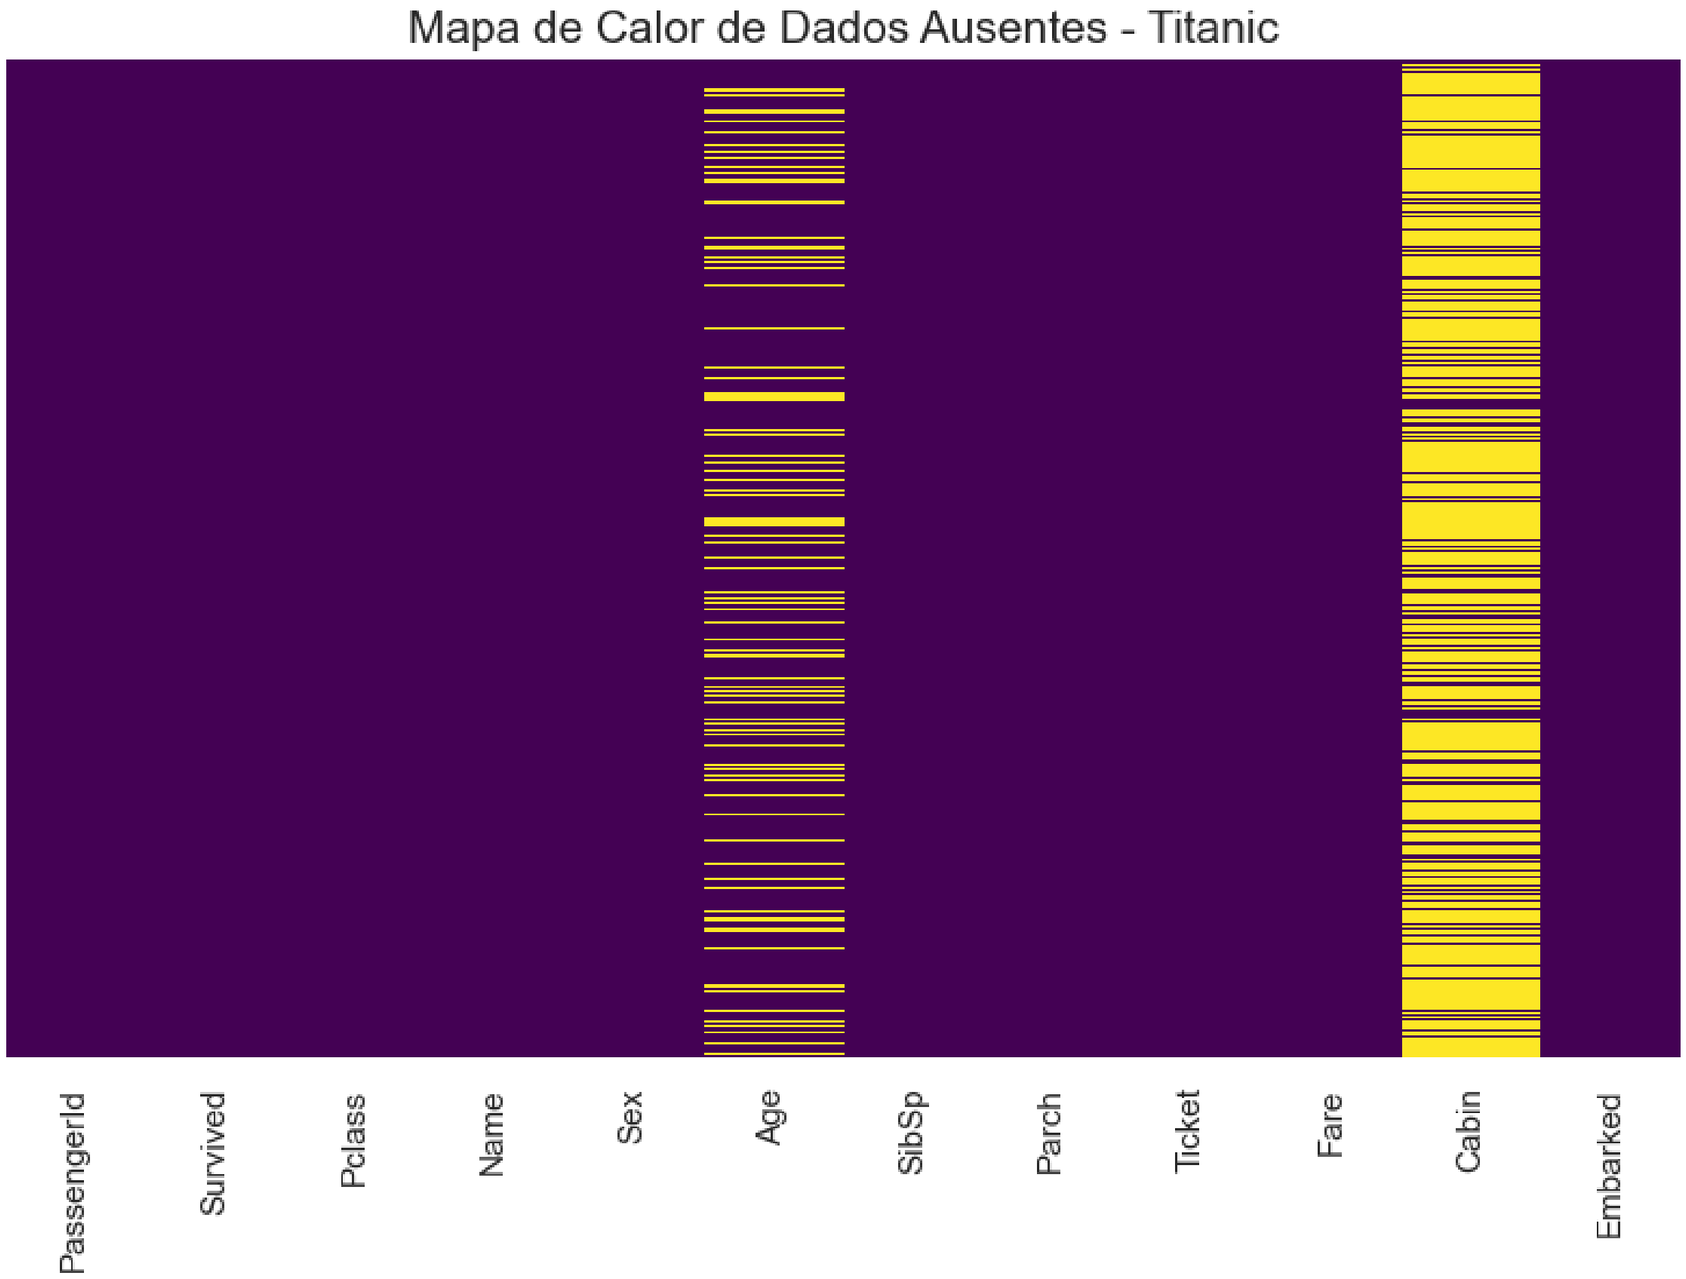
Mapa de Calor de Dados Ausentes - Titanic
PassengerId
Survived
Pclass
Name
Sex
Age
SibSp
Parch
Ticket
Fare
Cabin
Embarked

Curativo Específico: Dicionários no fillna()

- O Pandas aceita a passagem de Dicionários Python como argumento.
- Permite definir uma regra de preenchimento exclusiva para cada coluna.
- Evita a contaminação cruzada de tipos de dados (dtypes).
- Mantém o rastreamento técnico (metadados) impecável.

```
curativos = {'Idade': 0, 'Cabine': 'Desconhecida'}

df.fillna(value=curativos, inplace=True)
```

Limitações de Valores Fixos

- Hardcoding (valores fixos como 0) distorce a realidade estatística.
- Zero não é uma idade válida e altera drasticamente a média real do dataset.
- O curativo ideal não é um número arbitrário, mas uma inferência lógica.
- Próximo Passo: Imputação com inteligência estatística.

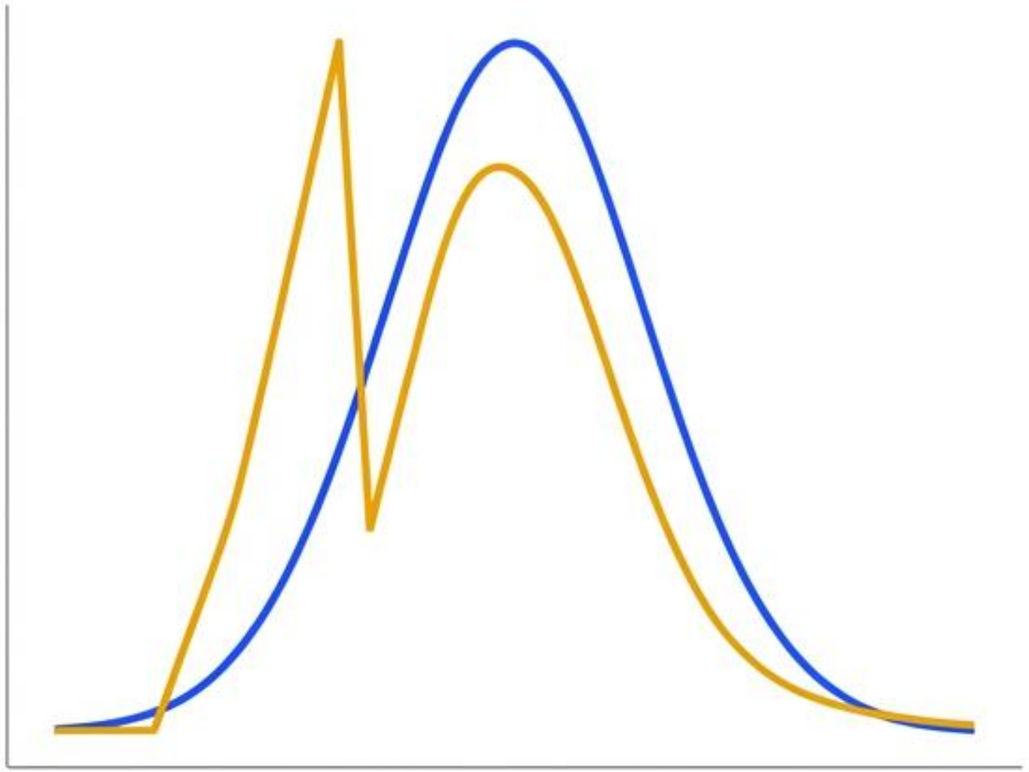

A "Seringa Inteligente": Imputação Estatística

- Transição de preenchimento manual para preenchimento estatístico.
- A relação matemática por trás do método **.fillna()**.

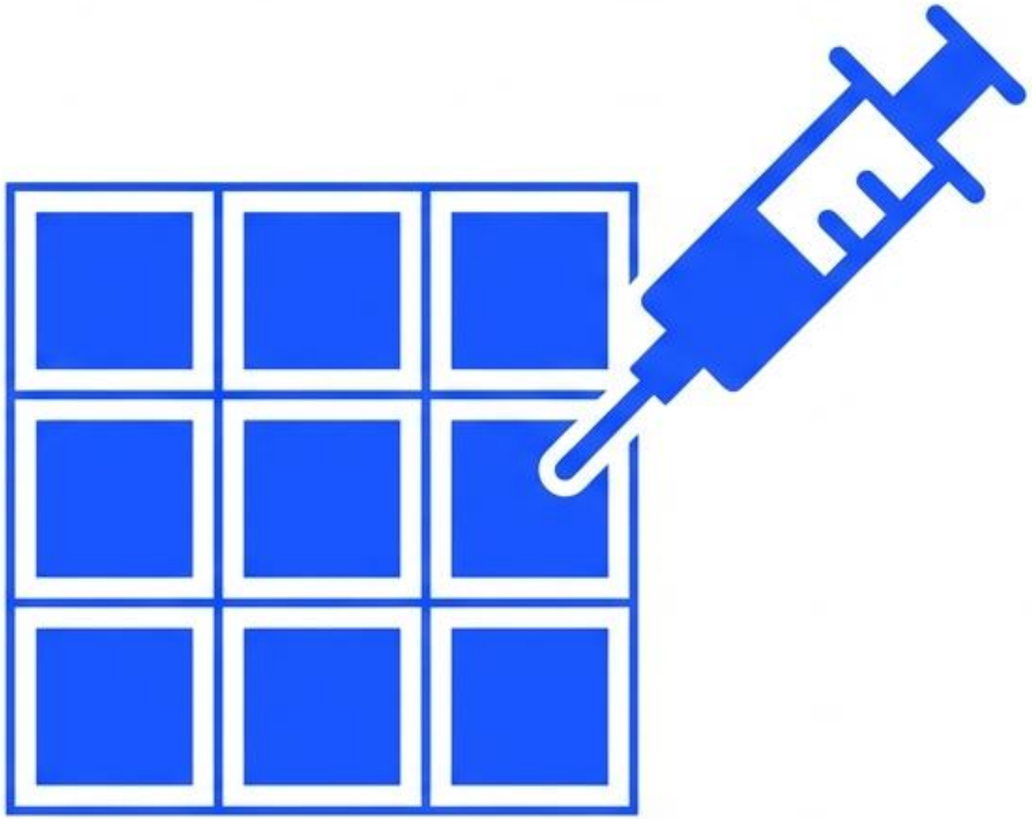

Imputação Dinâmica com .fillna()

- **Abordagem cega:** Risco grave de distorção da realidade.
- **Abordagem estatística:** Preenchimento baseado na tendência central.
- **Cálculo automatizado:** O Pandas ignora os NaN ao calcular a média.

```
df['coluna'].fillna(0) # Abordagem Cega

df['coluna'].fillna(df['coluna'].mean()) # Abordagem Inteligente
```

Média vs. Mediana: O Fator Outlier

- **Média**: Altamente sensível a valores extremos (Outliers).
- **Mediana**: Medida de posição robusta, corta o dataset exatamente ao meio.
- Regra de Ouro: Alta variância exige o uso da mediana.

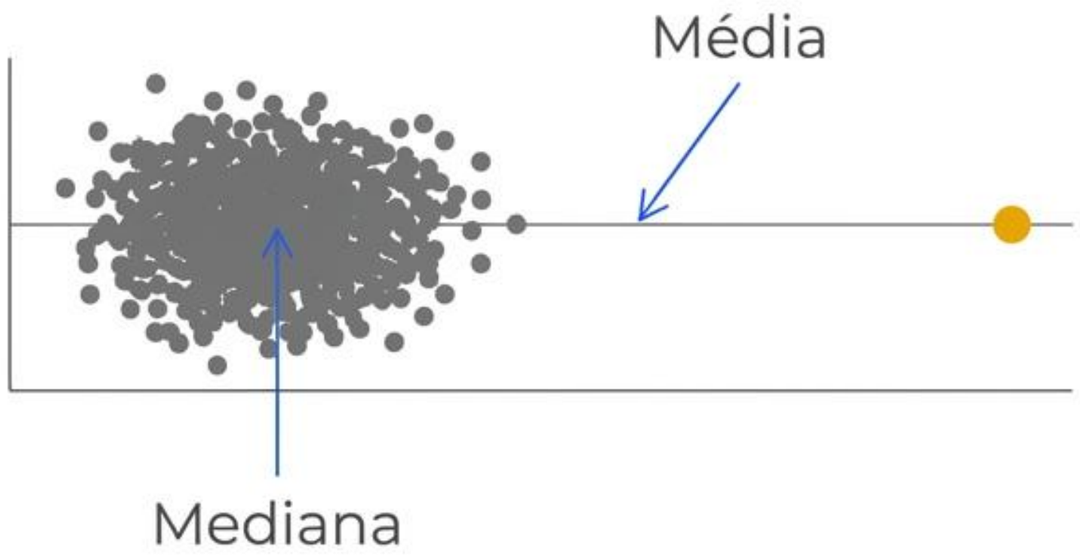

Hands-on: A Cirurgia de Dados (Lab 05)

- Passo 1: Amputação. Descartar colunas com > 70% de dados ausentes (dropna).
- Passo 2: Diagnóstico. Avaliar a presença de outliers nas colunas restantes.
- Passo 3: Intervenção. Preencher vazios utilizando fillna() com a medida estatística adequada.

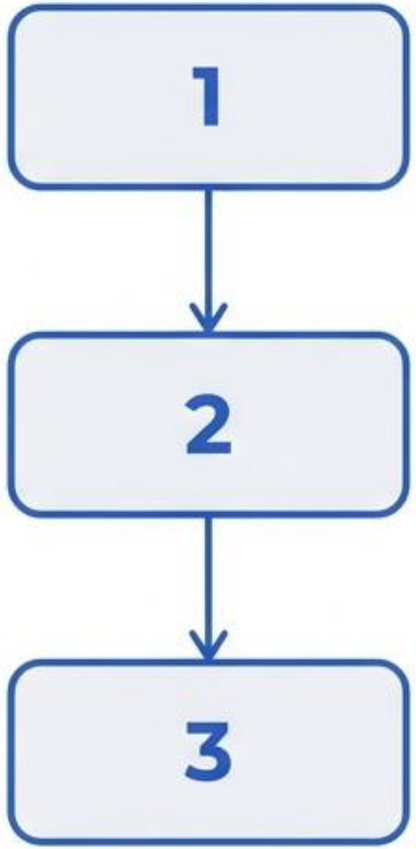

O Risco Oculto do Tratamento Univariado

- **Cegueira de Correlação:** Analisa a coluna em completo isolamento.
- **Distorção da Variância:** Inserir a mesma média repetidas vezes esmaga a curva de distribuição.
- **Viés Estatístico:** Falsa confiança em modelos de Machine Learning futuros.

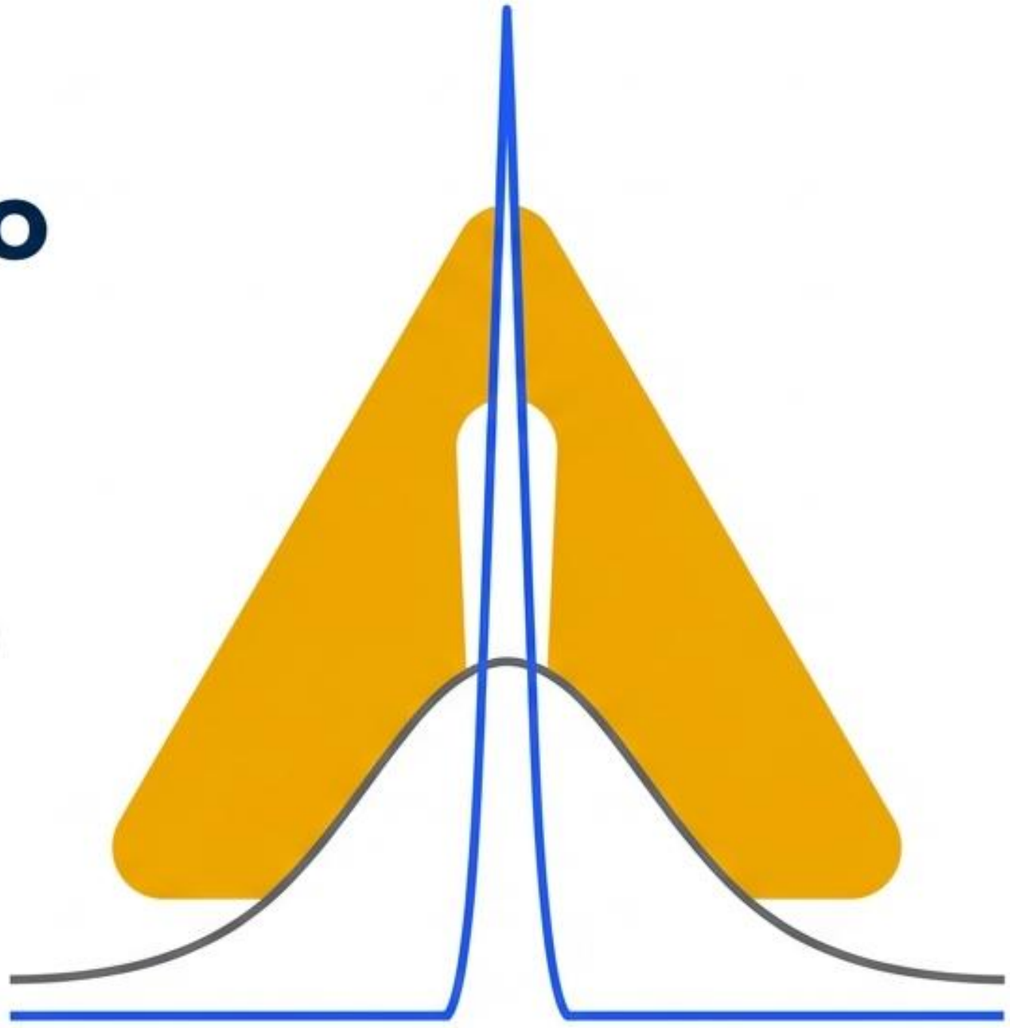

Dados Ausentes: O
O Paradigma Multivariado

Disciplina: Extração e Preparação de Dados (IBM8915)

Tópico: Imputação Iterativa e Laboratório Prático (Parte 2)

Professor: Luís Aramis

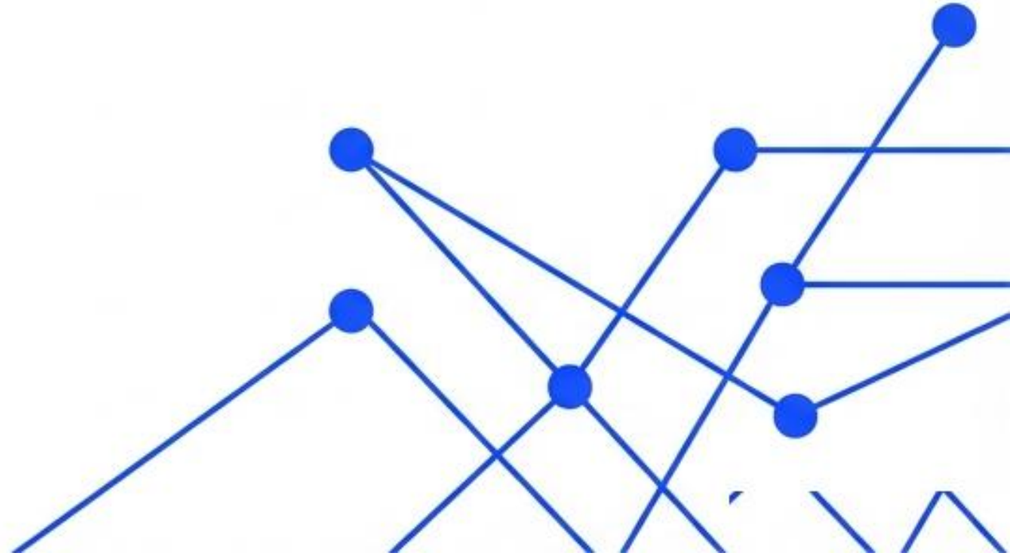

Iterative Imputer: A Matemática da Previsão

- KNN: Baseia-se na distância espacial entre registros similares.
- Iterative Imputer: Cria uma equação matemática (Regressão) para cada lacuna.
- Exemplo Prático: A variável 'Idade' (ausente) torna-se o alvo (Y) previsto pelas variáveis 'Salário' e 'Tarifa' (X).

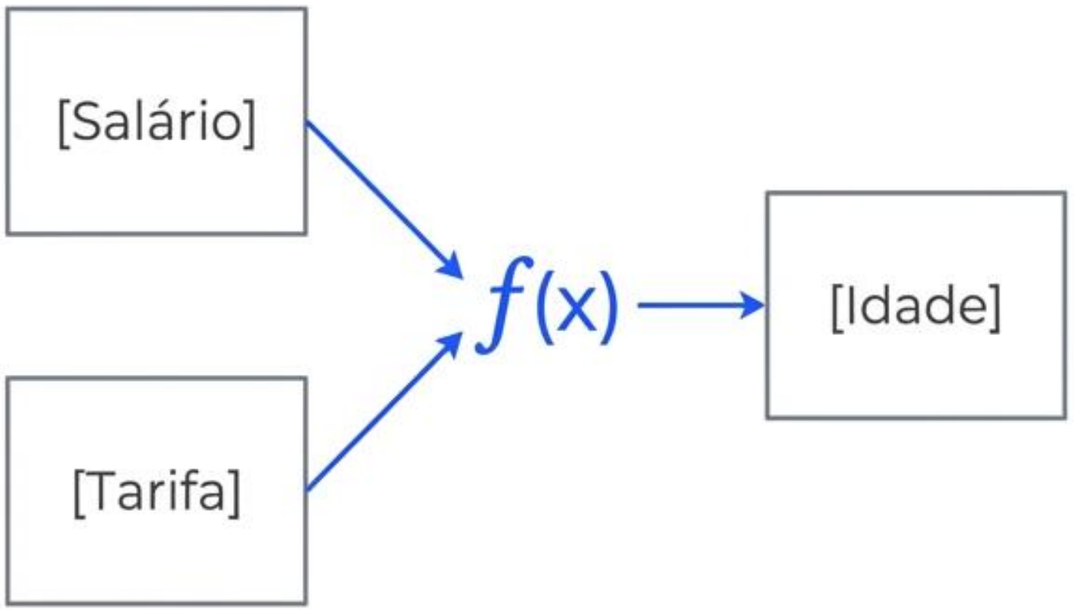

Scikit-Learn: Sintaxe e o ValueError

- Ativação experimental obrigatória no Scikit-Learn.
- Instanciação do modelo e aplicação da transformação matemática.
- O Risco Crítico: Falha total de processamento em matrizes mistas.

```
from sklearn.experimental import enable_iterative_imputer
from sklearn.impute import IterativeImputer

Terminal error:
ValueError: could not convert string to float: 'Rio de Janeiro'
```

A Regra de Ouro: Isolamento de Variáveis

- Modelos preditivos processam exclusivamente matrizes numéricas.
- Separação Obrigatória: Isolar dados de texto (categóricos) antes de qualquer imputação.
- Reconstrução Segura: Concatenar as matrizes tratadas com os rótulos originais do Pandas.

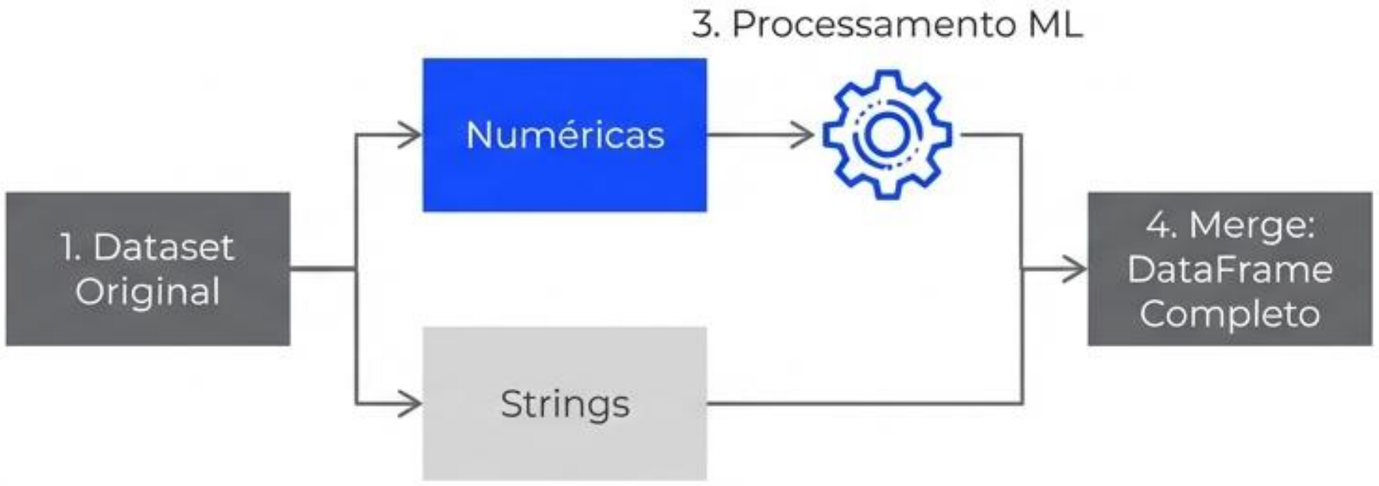

Dados Ausentes: Tratamento Multivariado

Além da Média: Imputação com K-Nearest Neighbors (KNN).

Disciplina: Extração e Preparação de Dados (IBM8915).

Professor: Luís Aramis.

Data: 10/03.

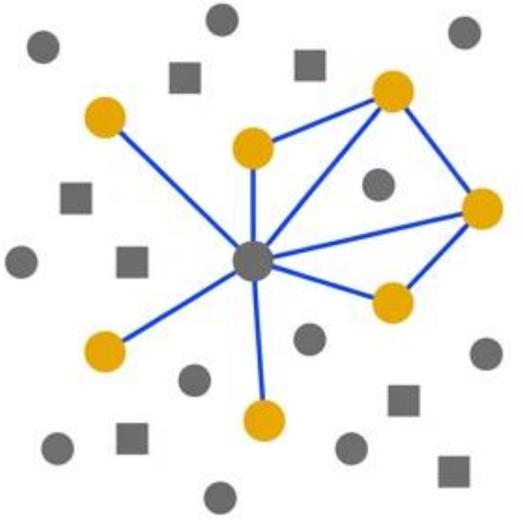

A Cegueira Contextual da Média

- O limite do método .fillna(df.mean()).
- Redução artificial da variância do dataset.
- Ignora correlações fundamentais entre as colunas.

O Paradigma Multivariado Multivariado

- Transição da análise vertical (coluna) para horizontal (linha).
- Variáveis com valores ausentes tornam-se funções das demais variáveis presentes.
- Preservação ativa das correlações internas originais do dataset.

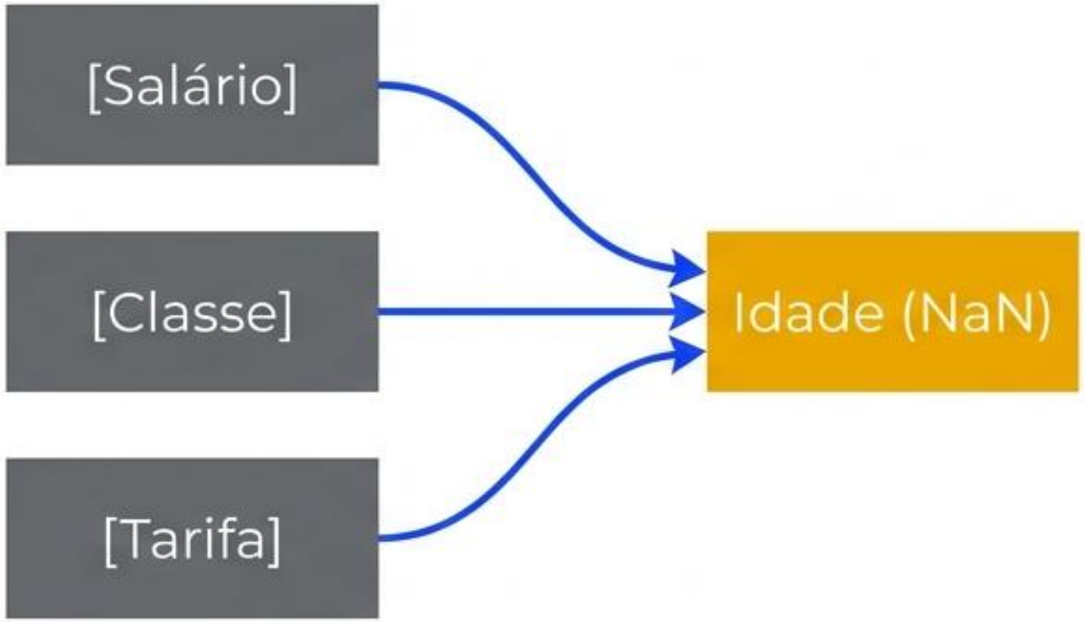

O Algoritmo K-Nearest Neighbors (KNN)

- **K:** O número predefinido de vizinhos a serem consultados.
- **Nearest:** A busca pelos registros mais similares no espaço de dados.
- A imputação ocorre pela média estrita destes K vizinhos idênticos.

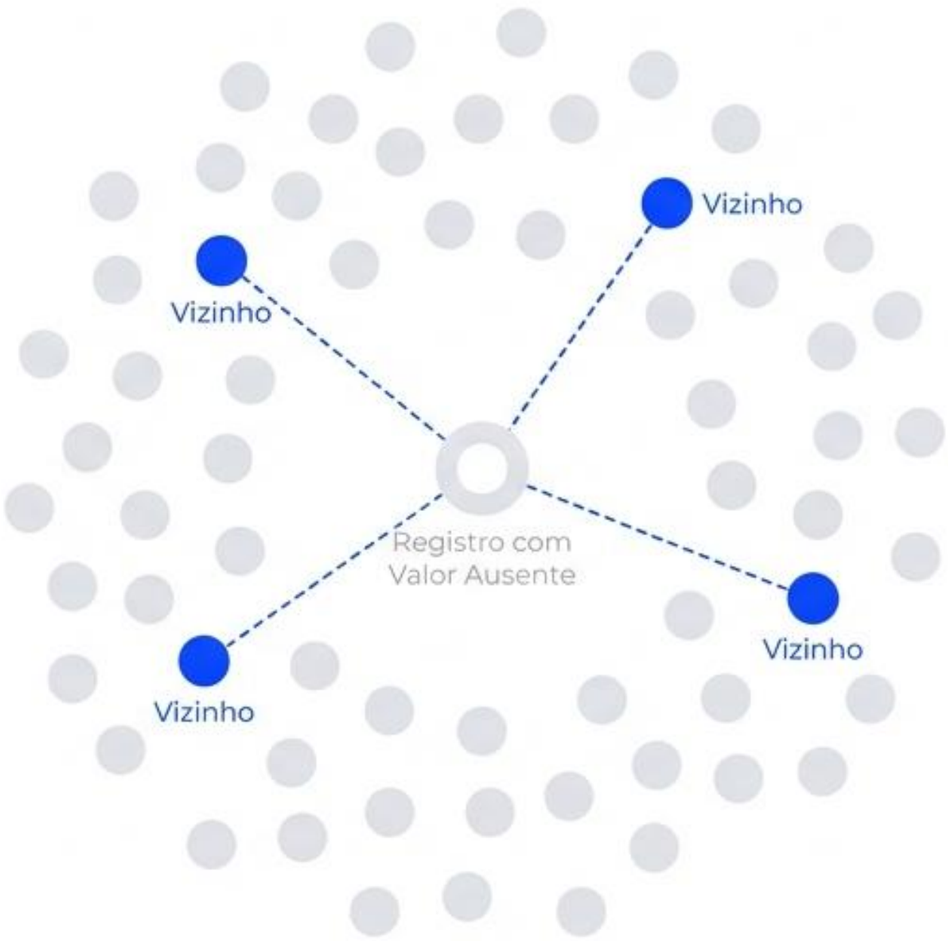

A Matemática da Vizinhança

- Cálculo de distâncias espaciais (ex: Distância Euclidiana).
- Dados transformados em coordenadas geométricas multi-eixos.
- A proximidade física no gráfico traduz a similaridade no negócio.

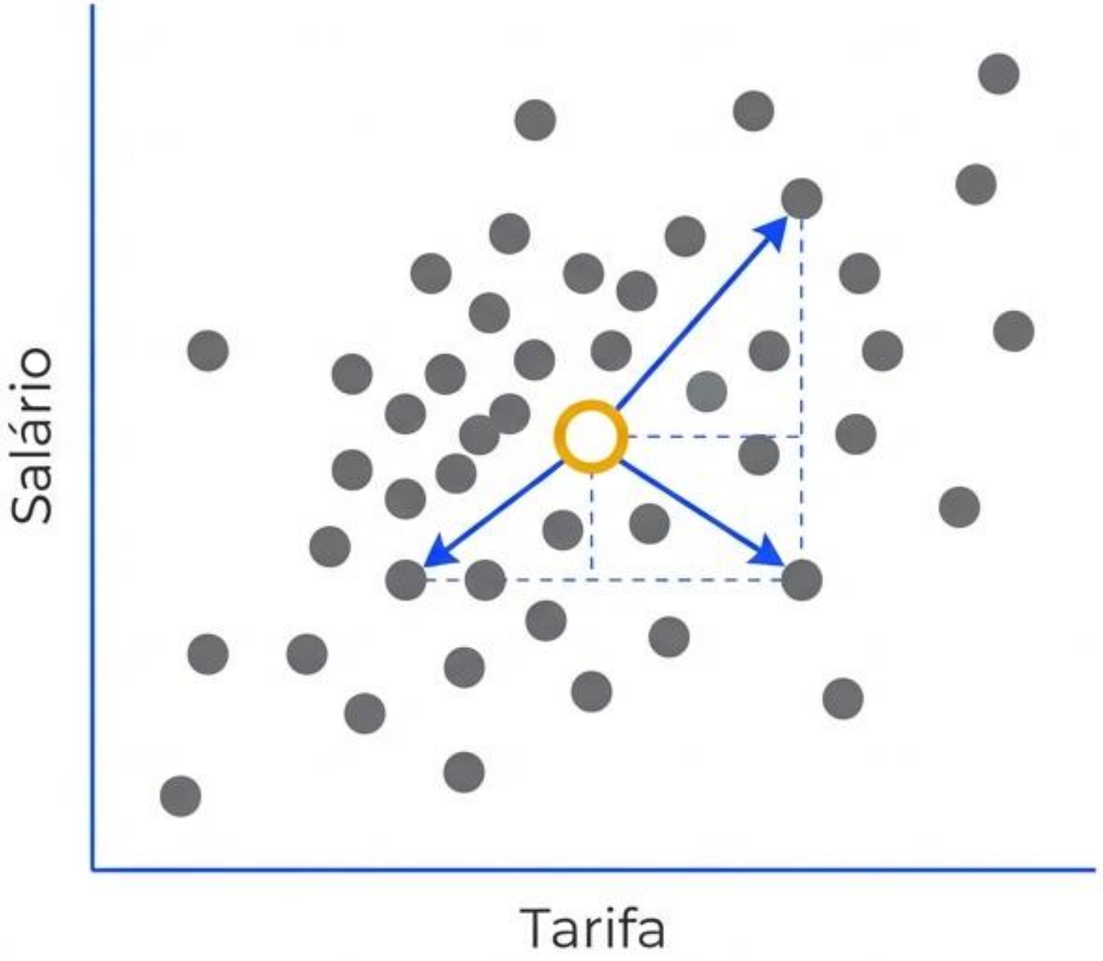

A Ponte para o Scikit-Learn

- Transição do ecossistema Pandas para o módulo sklearn.impute.
- Classe principal: KNNImputer.
- Introdução ao fluxo de Machine Learning (Treino e Aplicação).

```
from sklearn.impute import KNNImputer

imputer = KNNImputer(n_neighbors=5)
```

O Choque de APIs: Pandas vs. NumPy

- Scikit-Learn consome DataFrames, mas não devolve DataFrames.
- O processamento interno converte dados para matrizes puras do NumPy.
- Perda dos rótulos (nomes de colunas e índices).

Pandas DataFrame (Com Nomes) → **KNNImputer** → **NumPy Array (Apenas Números/Sem Rótulos)**

Reconstrução Estrutural

- Passo 1: Isolar variáveis numéricas (Scikit-Learn não lê texto).
- Passo 2: Executar .fit_transform() para imputar.
- Passo 3: Envelopar o resultado de volta em um pd.DataFrame.

```
# O retorno é um NumPy Array
dados_imputados = imputer.fit_transform(
df_numerico)

# Recriando o DataFrame
df_salvo = pd.DataFrame(dados_imputados,
columns=df_numerico.columns)
```

Preparação para o Laboratório Prático

- **Ferramenta:** Jupyter Notebook (lab_05_imputation.ipynb).
- **Missão:** Substituir o tratamento da Aula 07 pelo KNNImputer.
- **Validação:** Comparar a nova distribuição estatística com .describe().

Hands-on: A Evolução da Cirurgia com KNN

- Missão: Curar o dataset da Aula 07 utilizando o algoritmo KNNImputer.
- Passo 1: Isolar rigorosamente as colunas numéricas em um array.
- Passo 2: Instanciar o imputador e transformar os dados.
- Passo 3: Converter a matriz de saída (NumPy) de volta para Pandas DataFrame.

`lab_05_imputation.ipynb`

Auditoria de Resultados: .describe()

- Comparação da variância pré e pós-imputação.
- Preservação integral do contexto relacional dos passageiros.
- Validação final da ausência de valores nulos.

.describe() Aula 07 (Simples)

	count	mean	std	min	25%	50%	75%	max
Age	891.0	29.699	13.002	0.42	22.00	29.699	35.00	80.00
Fare	891.0	32.204	49.693	0.00	7.91	14.454	31.00	512.32

.describe() Aula 08 (KNN)

	count	mean	std	min	25%	50%	75%	max
Age	891.0	29.802	**14.321**	0.42	21.00	28.00	38.00	80.00
Fare	891.0	32.305	**49.750**	0.00	7.91	14.454	31.00	512.32

A Limitação Categórica

- As colunas numéricas foram restauradas de forma inteligente.
- Variáveis de texto (Categóricas) permanecem esburacadas ou com estatística pobre.
- A Próxima Fronteira: Conversão sem criar falsa hierarquia matemática.

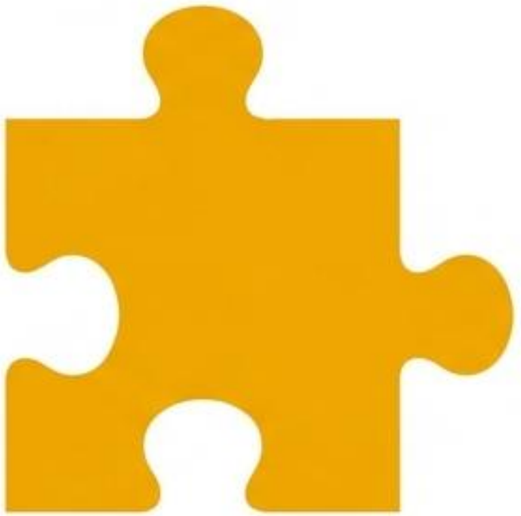

Aula 08 ⟶ Aula 10

Versionamento e Evolução

- Commit do notebook lab_05_imputation.ipynb.
- Mensagens de commit semânticas e profissionais.
- Próxima Aula: Imputação Multivariada (O algoritmo KNN).

```
git add lab_05_imputation.ipynb
git commit -m "feat: imputacao univariada com media e moda"
git push origin main
```

Dúvidas?

CRIATIVIDADE
INOVAÇÃO
¡DEIA!
COMAMUNIDADE
CRIATIVIDADE
BRAINSTORM
INOVAÇÃO

ibmec

A direção do amanhã.

/ibmec