Extração e Preparação de Dados

Aula 08 – Dados Ausentes: Tratamento Univariado e Multivariado

ibmec

Quem sou eu?

Professor: Luís Aramis dos Reis Pinheiro.

- **Doutorado e Mestrado** em **Ciências Mecânicas** – **UnB** – **CAPES 7**
- **Graduação** em Licenciatura em Física – **UNIFAP**

luis.pinheiro@professores.ibemec.edu.br

(96) 99907-5819

@l_aramis

Aula passada*

Hands-on: A Cirurgia de Dados (Lab 05)

- Passo 1: Amputação. Descartar colunas com > 70% de dados ausentes (dropna).
- Passo 2: Diagnóstico. Avaliar a presença de outliers nas colunas restantes.
- Passo 3: Intervenção. Preencher vazios utilizando fillna() com a medida estatística adequada.

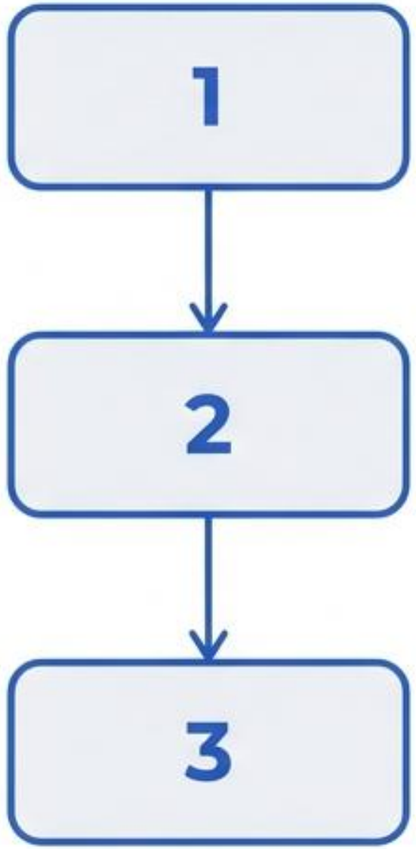

O Risco Oculto do Tratamento Univariado

- **Cegueira de Correlação:** Analisa a coluna em completo isolamento.
- **Distorção da Variância:** Inserir a mesma média repetidas vezes esmaga a curva de distribuição.
- **Viés Estatístico:** Falsa confiança em modelos de Machine Learning futuros.

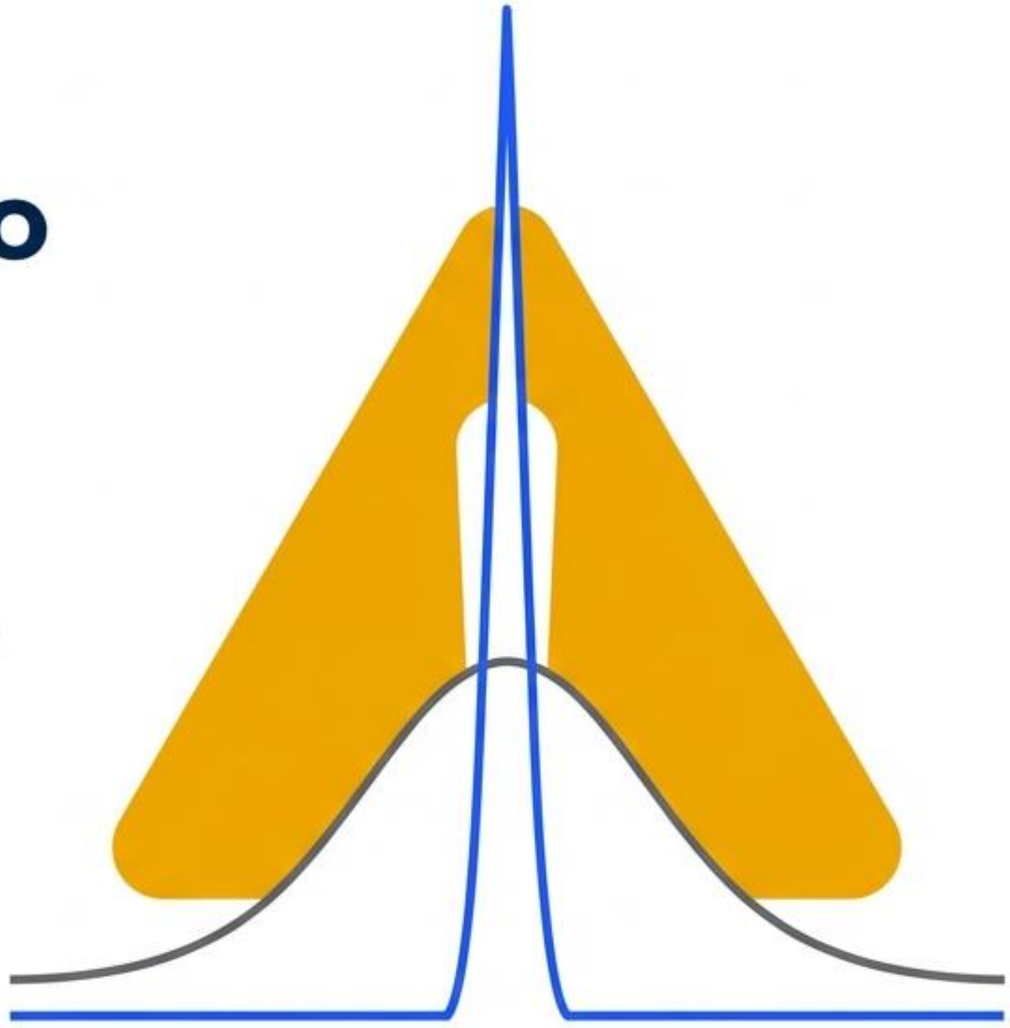

O Algoritmo K-Nearest Neighbors (KNN)

- **K:** O número predefinido de vizinhos a serem consultados.
- **Nearest:** A busca pelos registros mais similares no espaço de dados.
- A imputação ocorre pela média estrita destes K vizinhos idênticos.

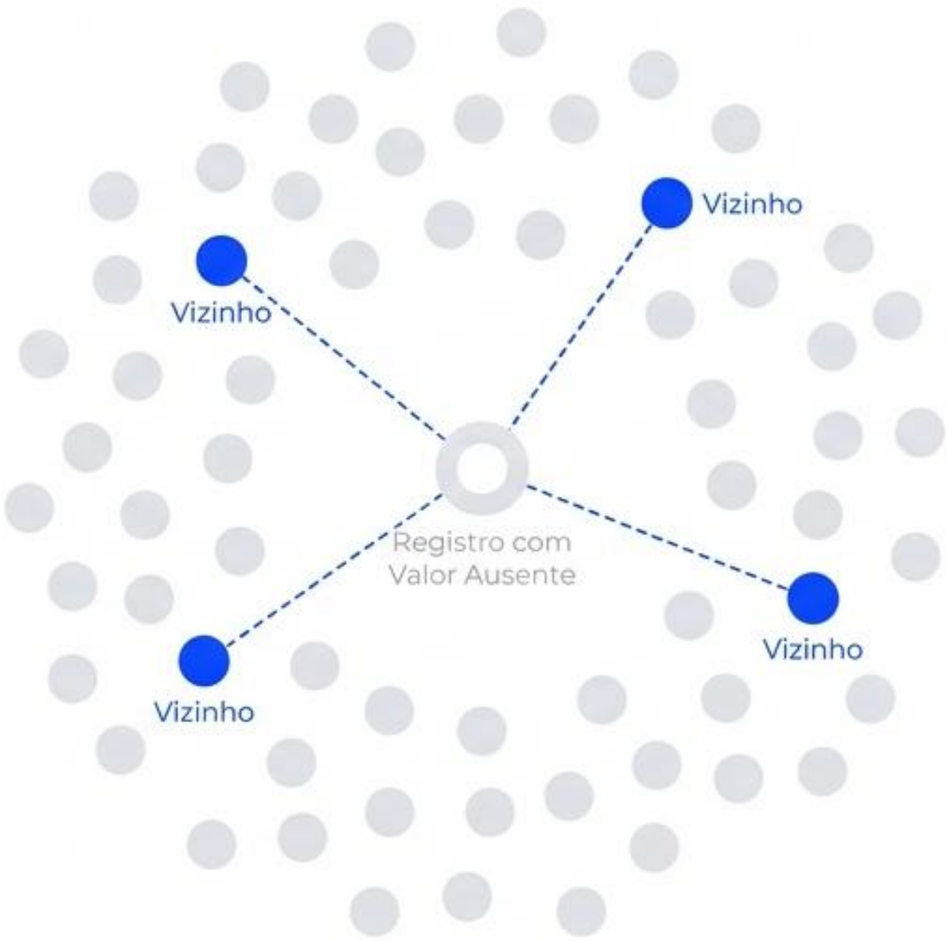

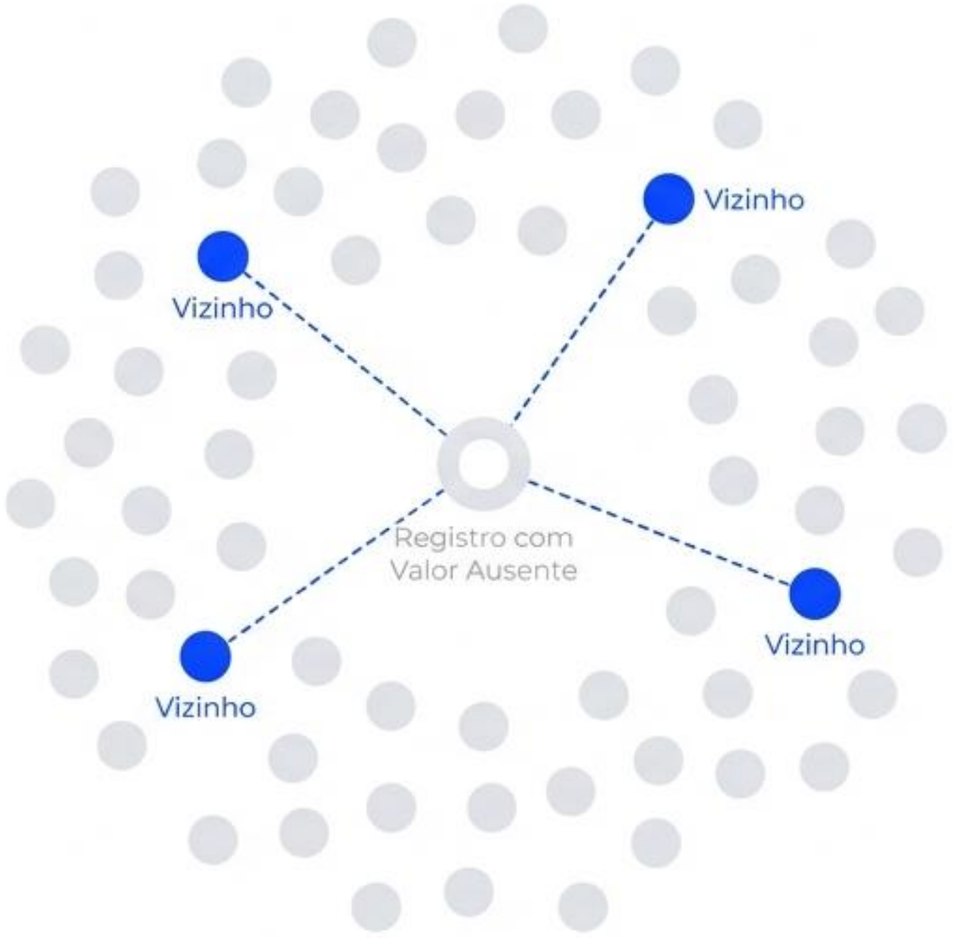
Vizinho
Vizinho
Registro com
Valor Ausente
Vizinho
Vizinho

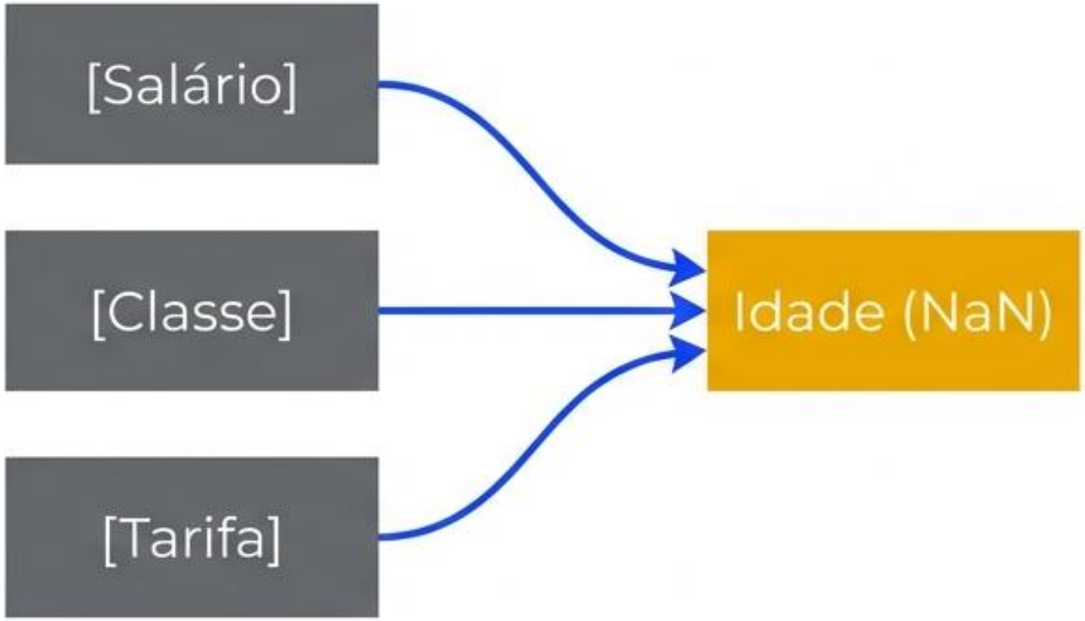
[Salário]
[Classe]
[Tarifa]
Idade (NaN)

A Matemática da Vizinhança

- Cálculo de distâncias espaciais (ex: Distância Euclidiana).
- Dados transformados em coordenadas geométricas multi-eixos.
- A proximidade física no gráfico traduz a similaridade no negócio.

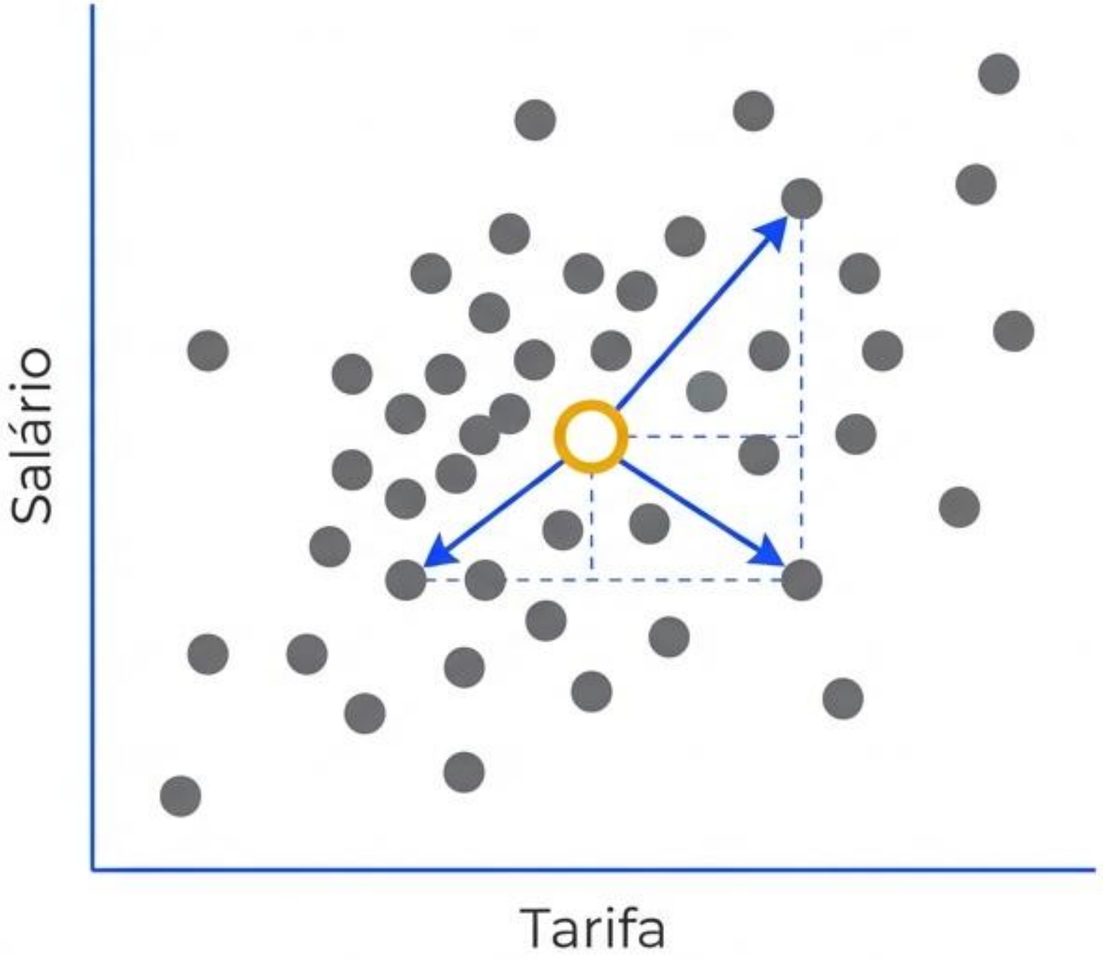

A Matemática da Vizinhança

A expressão matemática para a distância entre a amostra com dado faltante x e uma amostra de treino x_i é:

$$d(x, x_i) = \sqrt{\frac{p}{p_{valido}} \sum_{j \in validos} (x^{(j)} - x_i^{(j)})^2}$$

Onde:

- p é o número total de *features* no seu conjunto de dados.
- p_{valido} é o número de *features* que têm valores não-nulos **tanto em x quanto em x_i**.
- O termo $\frac{p}{p_{valido}}$ é o fator de correção que "escala" a distância para que ela seja comparável às distâncias onde nenhum dado está faltando.

A Matemática da Vizinhança

A expressão matemática para a distância entre a amostra com dado faltante x e uma amostra de treino x_i é:

$$d(x, x_i) = \sqrt{\frac{p}{p_{valido}} \sum_{j \in validos} (x^{(j)} - x_i^{(j)})^2}$$

Onde:

- p é o número total de *features* no seu conjunto de dados.
- p_{valido} é o número de *features* que têm valores não-nulos **tanto em x quanto em x_i**.
- O termo $\frac{p}{p_{valido}}$ é o fator de correção que "escala" a distância para que ela seja comparável às distâncias onde nenhum dado está faltando.

A Matemática da Vizinhança

A. Pesos Uniformes (`weights='uniform'` - Padrão)

O valor imputado $\hat{x}^{(m)}$ é a média simples da *feature* m entre os vizinhos que **possuem** esse valor. Se um vizinho também tiver a *feature* m ausente, ele é ignorado neste cálculo.

$$\hat{x}^{(m)} = \frac{1}{k_{valido}} \sum_{x_i \in N_k(x)} x_i^{(m)}$$

Onde k_{valido} é a quantidade de vizinhos dentre os k mais próximos que de fato possuem um valor real para a *feature* m.

Tratamento de Categorias e Cardinalidade

Redução de Ruído e o Fenômeno da Cauda Longa

Disciplina: Extração e Preparação de Dados (IBM8915)

Data: 10/03/2026

O Paradigma do Texto

- **A Barreira da Máquina:** Algoritmos de Machine Learning exigem dados numéricos, não palavras.
- **O Objetivo Final:** Transformar variáveis nominais em matrizes puramente matemáticas.
- **O Passo Crítico:** Limpar o ruído textual antes de realizar a tradução.

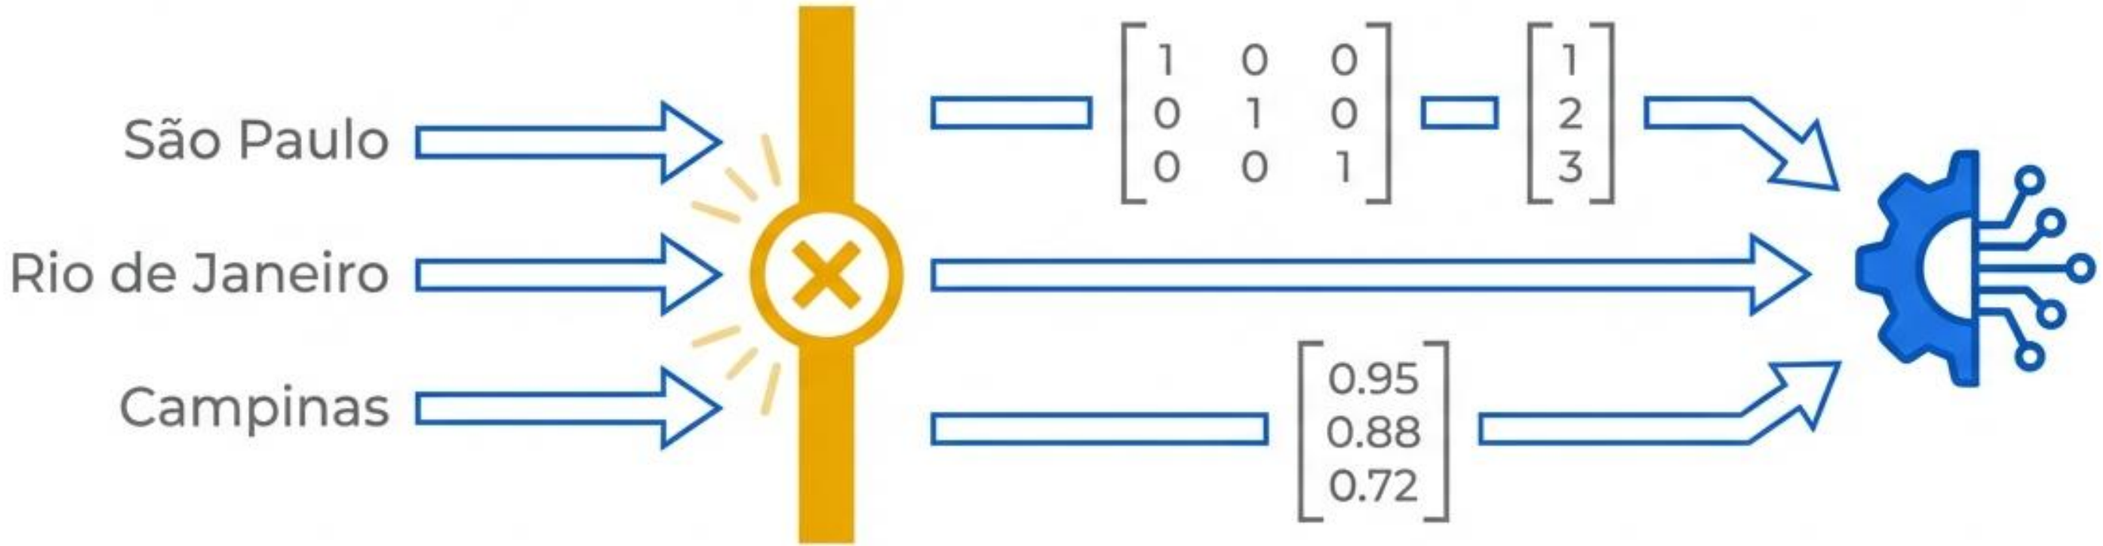

A Ameaça da Alta Cardinalidade

- O Fenômeno da Cauda Longa (Long Tail).
- Concentração massiva em poucas categorias dominantes.
- Poluição do dataset por centenas de categorias raras.

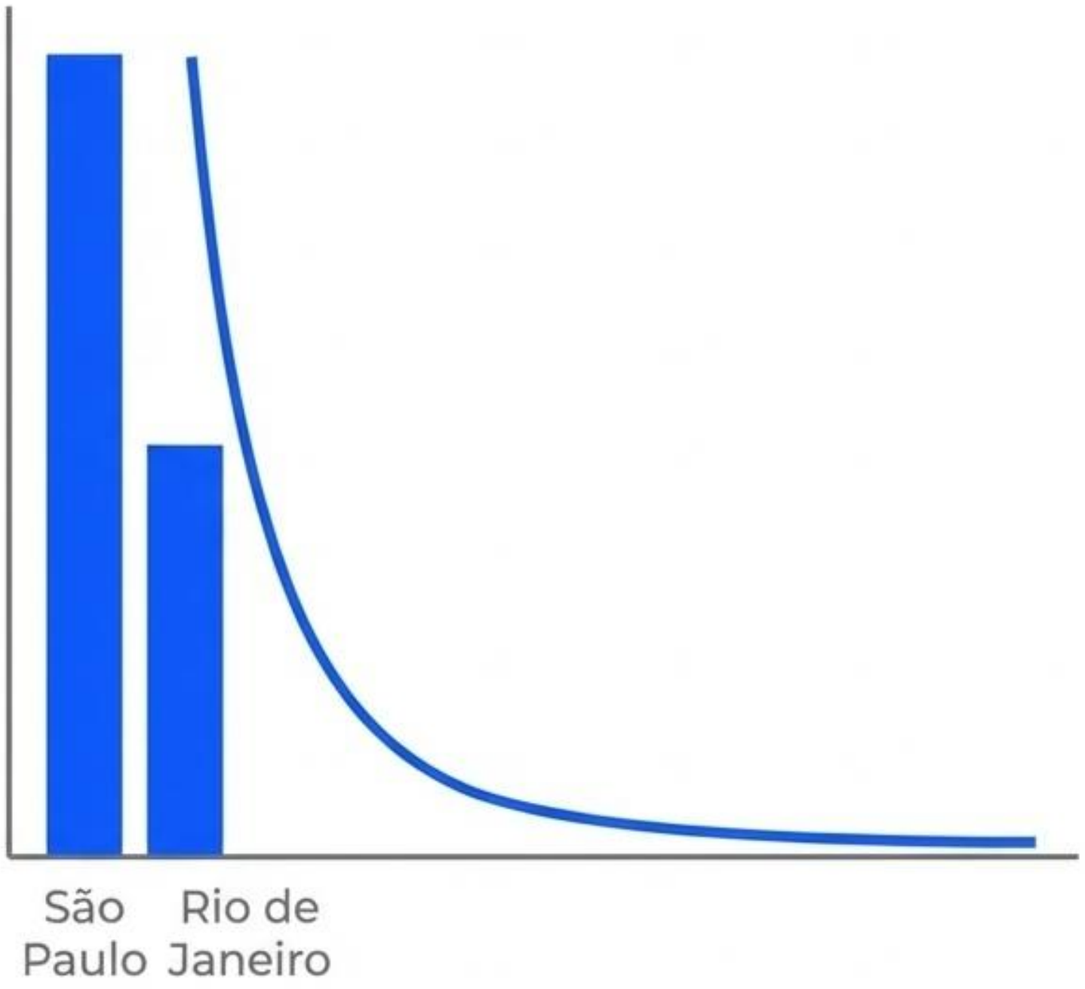

Diagnóstico: Quantificando o Ruído

- Identificação estatística da frequência de cada categoria.
- Mapeamento das proporções para encontrar o limite de corte (threshold).

```
frequencias = df['cidade'].value_counts(normalize=True)
```

A Estratégia de Binning

- Definição de um limite de corte estatístico rigoroso.
- Agrupamento de todas as categorias minoritárias.
- Criação do rótulo global unificado: ‘Outros’.

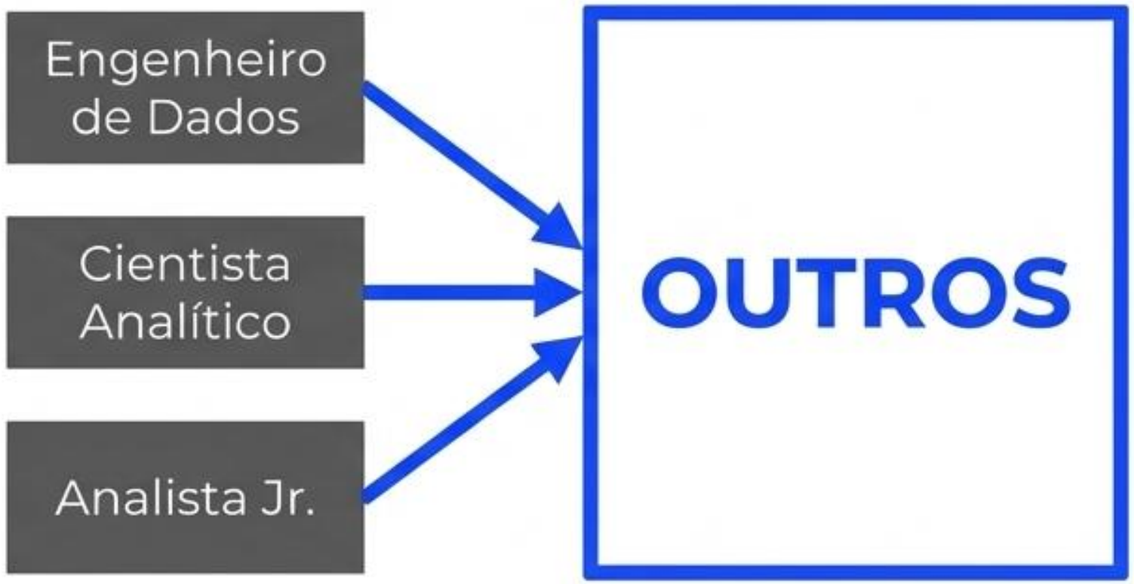

A Solução: Binning Categórico

A Estratégia: Agrupar **categorias de baixa frequência** em um único **rótulo majoritário**.

```
# Isolando quem é raro
raros = frequencias[frequencias < 0.02].index

# Esmagando o ruído (Máscara Booleana)
df.loc[df['cidade'].isin(raros), 'cidade'] = 'Outros'
```

A Execução: Uso de máscaras booleanas (.loc e .isin()) ou np.where.

- Reduz drasticamente a dimensionalidade antes da tradução matemática.

Check de Aprendizado: A Explosão Dimensional

- **Cenário:** Uma base de RH possui 850 profissões únicas listadas via .nnique().
- **Ação Omissa:** Você ignora o Binning e tenta traduzir as 850 profissões direto para a linguagem da máquina.
- **Pergunta:** Qual é a consequência computacional exata no seu DataFrame?

Laboratório 06: Esmagando a Cardinalidade

- Abra o notebook local: `lab_06_cardinality.ipynb`.
- Diagnostique o ruído textual com `value_counts`.
- Isole e substitua os valores minoritários com a **máscara booleana** (`isin()`).
- Prepare a coluna purificada para o **Segundo Tempo** da aula.

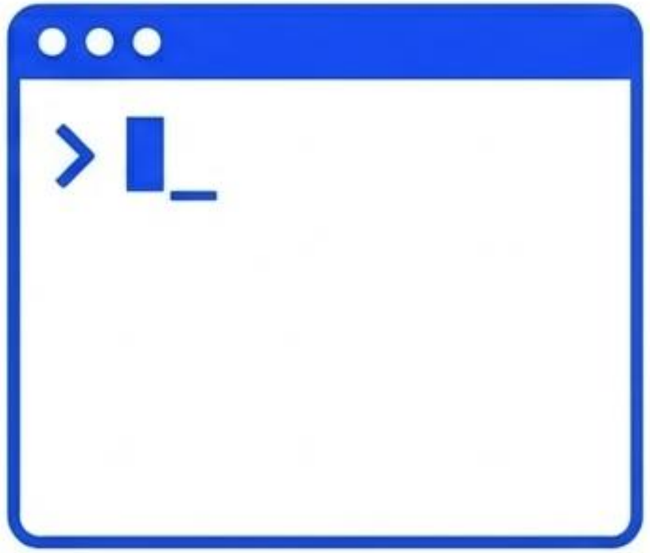

O Paradigma Dummy

- A máquina não lê texto: necessidade absoluta de tradução.
- Transformação de strings nativas para matrizes matemáticas.
- Preparação de variáveis nominais para o Scikit-Learn.

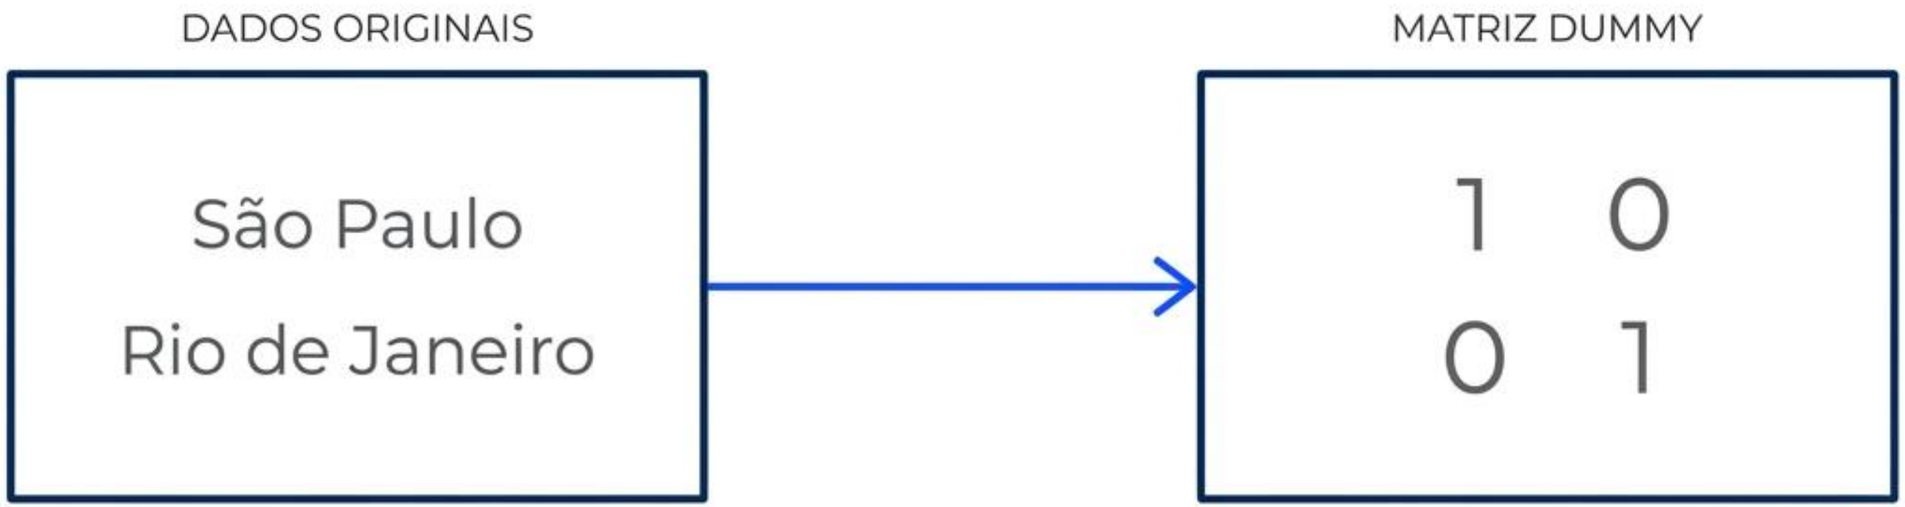

O Perigo da Falsa Hierarquia

- **O problema nominal**: números inteiros criam falsas correlações.
- **A interpretação da máquina**: algoritmos tratam números como pesos de grandeza.
- **A regra de ouro**: nunca utilize Ordinal Encoding para categorias nominais.

Verde (3) > Azul (2) > Vermelho (1)

A Solução do One-Hot Encoding

- Criação de uma **nova coluna booleana isolada** para cada categoria.
- Geração de uma **Matriz Esparsa**: **valores 1 (verdadeiro) ou 0 (falso)**.
- **Neutralidade matemática** garantida com **pesos idênticos**.

Cor	Cor_Azul	Cor_Verde	Cor_Vermelho
Verde	0	1	0
Azul	1	0	0
Vermelho	0	0	1

A Armadilha da Variável Dummy

- A colinearidade perfeita quebra modelos preditivos lineares.
- A necessidade obrigatória de estabelecer uma categoria base.
- A regra paramétrica essencial: `drop_first=True`

$$A = 1 - B - C$$

(Se não é Azul, nem Verde, a máquina já deduz perfeitamente que é Vermelho)

Tradução Matemática com Pandas

- Abstração da complexidade matemática através da biblioteca Pandas.
- Conversão direta de strings para matrizes **binárias** com um único comando.
- Integração fluida com o DataFrame original.

```
df_encoded = pd.get_dummies(df, columns=['Profissao'], drop_first=True)
```

Hands-on: O Tradutor de Dados

1. Abertura do ambiente: lab_07_encoders.ipynb
2. Recuperação da coluna de Cauda Longa limpa no primeiro tempo da aula.
3. Aplicação prática da dummificação para redução final de cardinalidade.
4. Verificação do shape (crescimento horizontal do dataset).

Versionamento e Entrega Semanal

- Nenhuma string deve restar na variável alvo preditiva.
- Consolidação dos dois laboratórios do dia no repositório.
- Atualização do portfólio de Ciência de Dados no GitHub.

```
git add lab_06_cardinality.ipynb lab_07_encoders.ipynb

git commit -m 'feat: agrupamento da cauda longa e dummificacao'

git push origin main
```

O Próximo Nível do Encoding

- O limite crítico de memória do One-Hot Encoding.
- O desafio de atributos logísticos com dezenas de milhares de rótulos (ex: CEPs).
- Preparação para o dia 12/03: Target Encoding e Binning Avançado.

Dúvidas?

CRIATIVIDADE
INOVAÇÃO
¡DEIA!
COMAMUNIDADE
CRIATIVIDADE
BRAINSTORM
INOVAÇÃO

ibmec

A direção do amanhã.

/ibmec