Extração e Preparação de Dados

Aula 09 – Encoding Avançado e discretização

ibmec

Quem sou eu?

Professor: Luís Aramis dos Reis Pinheiro.

- **Doutorado e Mestrado** em **Ciências Mecânicas** – **UnB** – **CAPES 7**
- **Graduação** em Licenciatura em Física – **UNIFAP**

luis.pinheiro@professores.ibemec.edu.br

(96) 99907-5819

@l_aramis

Aula passada*

O Perigo da Falsa Hierarquia

- **O problema nominal**: números inteiros criam falsas correlações.
- **A interpretação da máquina**: algoritmos tratam números como pesos de grandeza.
- **A regra de ouro**: nunca utilize Ordinal Encoding para categorias nominais.

Verde (3) > Azul (2) > Vermelho (1)

A Solução do One-Hot Encoding

- Criação de uma **nova coluna booleana isolada** para cada categoria.
- Geração de uma **Matriz Esparsa**: **valores 1 (verdadeiro) ou 0 (falso)**.
- **Neutralidade matemática** garantida com **pesos idênticos**.

Cor	Cor_Azul	Cor_Verde	Cor_Vermelho
Verde	0	1	0
Azul	1	0	0
Vermelho	0	0	1

O Próximo Nível do Encoding

- O limite crítico de memória do One-Hot Encoding.
- O desafio de atributos logísticos com dezenas de milhares de rótulos (ex: CEPs).
- Preparação para o dia 12/03: Target Encoding e Binning Avançado.

Encoding Avançado e Discretização

— Domando a Alta Cardinalidade e Agrupando Números

— Extração e Preparação de Dados (IBM8915)

— 12/03/2026

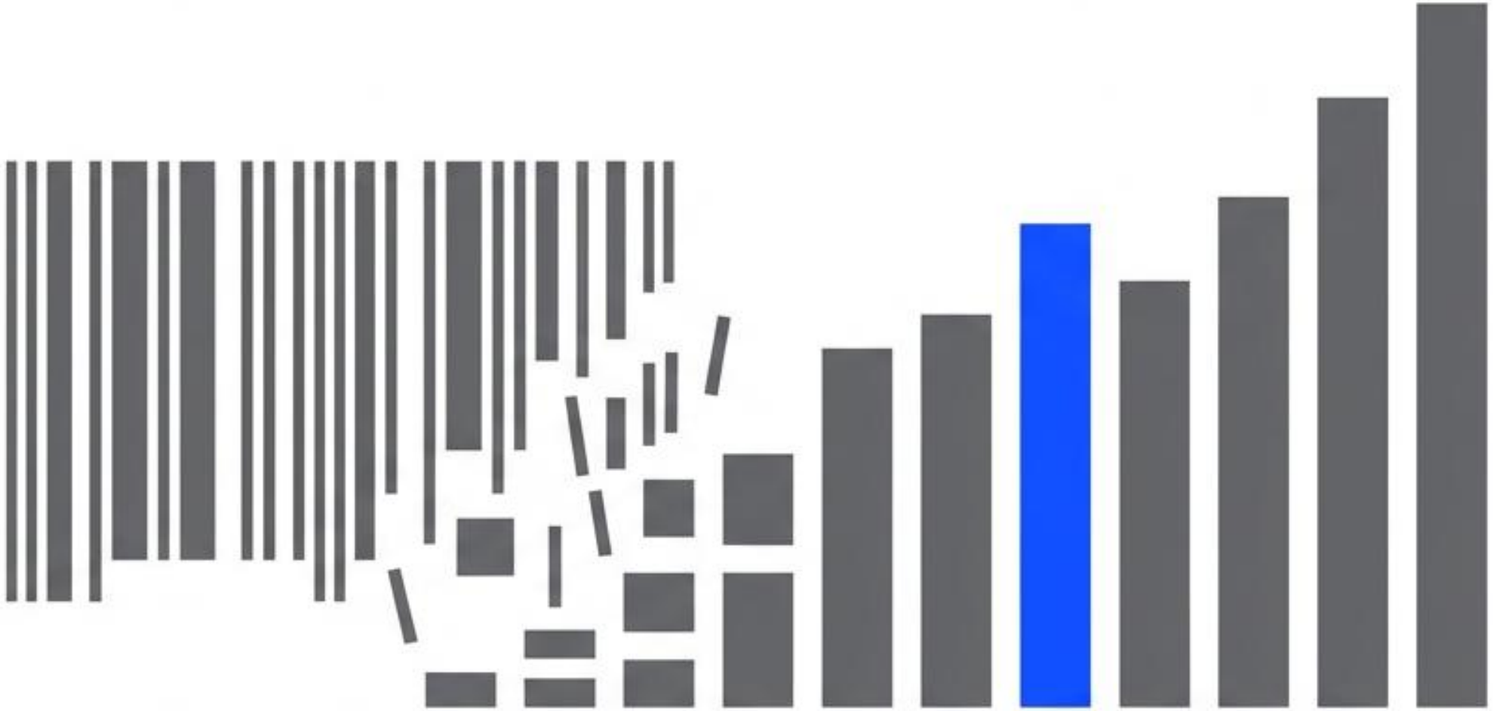

O Paradigma do CEP: O Limite da Matriz

- **A Barreira do `One-Hot Encoding`:** Inviável para variáveis textuais com altíssima cardinalidade.
- **Explosão de Dimensionalidade:** Uma única coluna de `CEPs` transforma-se em milhares de novas colunas.
- **Ameaça Computacional:** Geração imediata de `MemoryError` e criação de matrizes esparsas inúteis para o algoritmo.

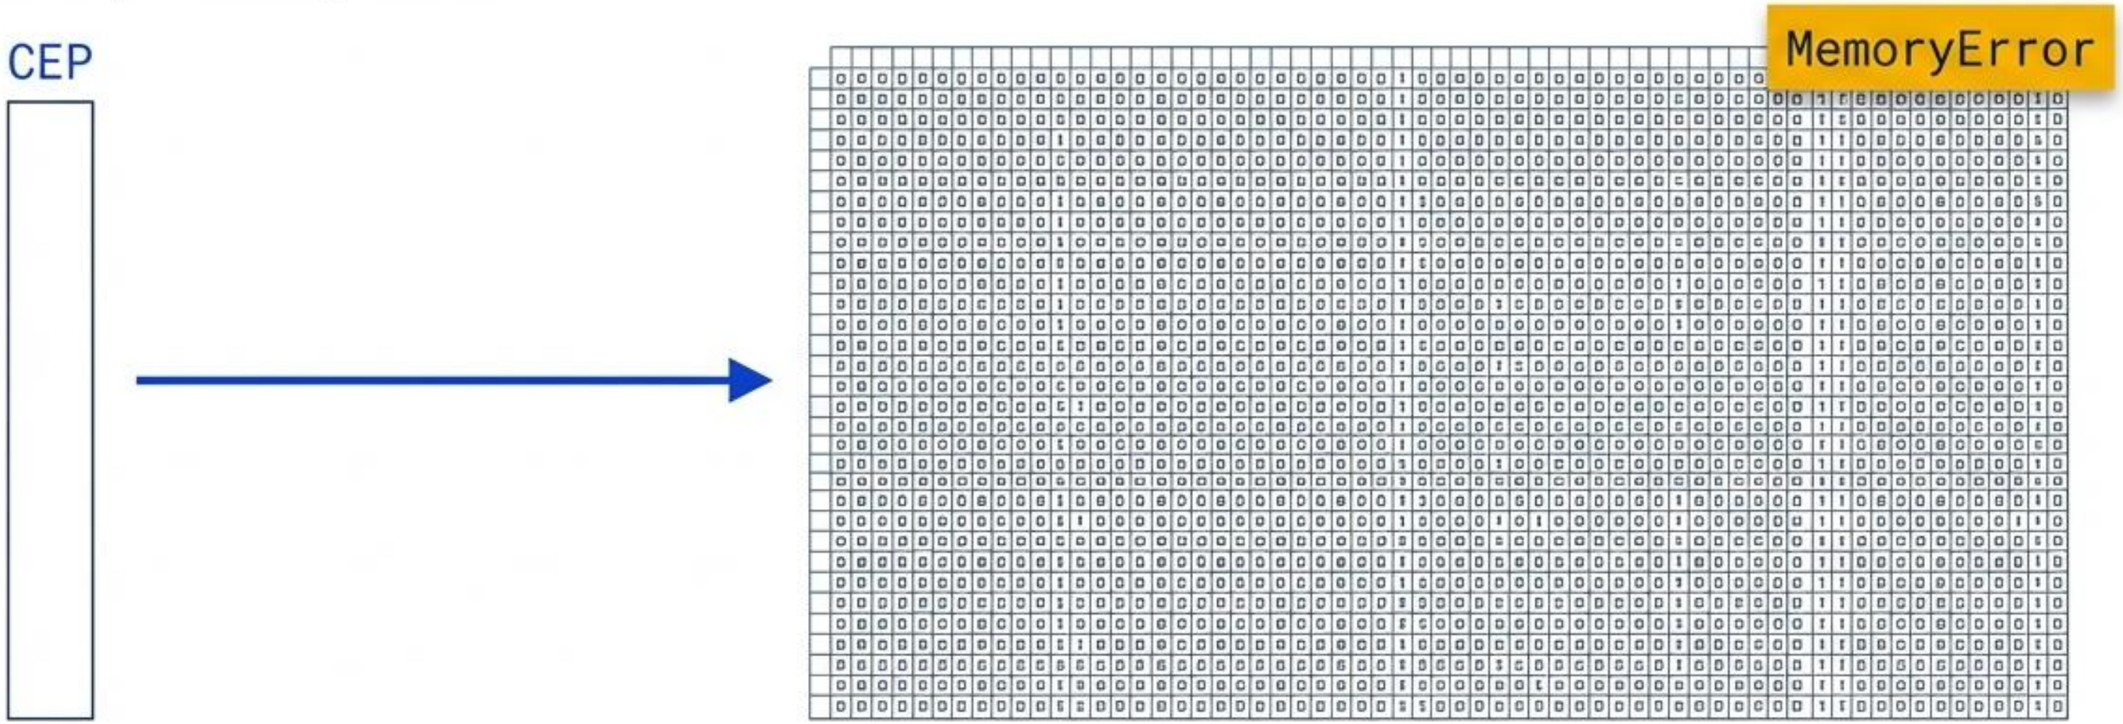

O CEP COMO VARIÁVEL CHAVE NA DETECÇÃO DE FRAUDE (E-COMMERCE & CARTÃO DE CRÉDITO)

COMO O MODELO ANALISA O CEP (TARGET ENCODING)

A TAXA HISTÓRICA DE FRAUDE DO CEP É USADA COMO PONTUAÇÃO (TARGET ENCODING)

1. PADRÕES DE QUADRILHAS E ROTAS

50+ CARTÕES DIFERENTES

PICO DE COMPRAS COM CARTÕES CLONADOS PARA O MESMO ENDEREÇO DE ENTREGA

TAXA HISTÓRICA DISPARA

2. ENDEREÇOS DE ALTO RISCO (GALPÕES FANTASMAS)

LOCAIS USADOS PRIMARIAMENTE PARA RECEBER MERCADORIAS COMPRADAS COM FRAUDE

ENDEREÇOS NÃO VERIFICADOS OU NÃO EXISTENTES

3. ROUBO DE CARGA E PERDA LOGÍSTICA

18% TAXA DE ROUBO DE CARGA

CEPs COM ALTAS TAXAS DE ROUBO DE CARGA NO TRAJETO

CLASSIFICAÇÃO DO SISTEMA: FRAUDE/PERDA LOGÍSTICA

Frequency Encoding: O Peso da Categoria

- **A Lógica:** Substitui a categoria (string) pela sua frequência relativa (peso) no dataset.
- **Eficiência:** Mantém a estrutura de uma única coluna (1D), eliminando a explosão de matrizes.
- **Implementação Pandas:** Mapeamento direto e veloz utilizando os métodos `.value_counts(normalize=True)` e `.map()`.

Cidade:
Rio de Janeiro → **Peso Operacional: 0.15 (15%)**

Target Encoding: A Probabilidade Histórica

- **O Conceito Preditivo:** Substitui a categoria pela média histórica da variável alvo (Target).
- **Mapeamento de Risco:** Traduz o nome do bairro ou CEP pela sua probabilidade matemática.
- **Atenção (Data Leakage):** Exige rigor estatístico; deve ser calculado estritamente nos dados de treino para evitar vazamento do futuro.

CEP (String) ⟶ `GroupBy(CEP)['Inadimplência'].mean()` ⟶ **Risco: 0.82**

Hands-on: O Fim do Lab 07

- **Ambiente:** Jupyter Notebook (`lab_07_encoders.ipynb`).
- **Objetivo:** Aplicar Target Encoding na variável categórica de alta cardinalidade.
- **Critério de Êxito:** Eliminação total de strings da variável preditora sem gerar expansão de matrizes.

```
df['CEP_encoded'] =
df['CEP'].map(target_mean)
```

Discretização de Dados (Binning): Da Exatidão à Categoria

- Redução de ruído analítico em variáveis contínuas de alta variabilidade.
- Agrupamento de valores matemáticos exatos em faixas categóricas (bins).
- Eliminação de variações milimétricas para revelação de macrotendências.
- Identificação de padrões comportamentais não-lineares para modelos preditivos.

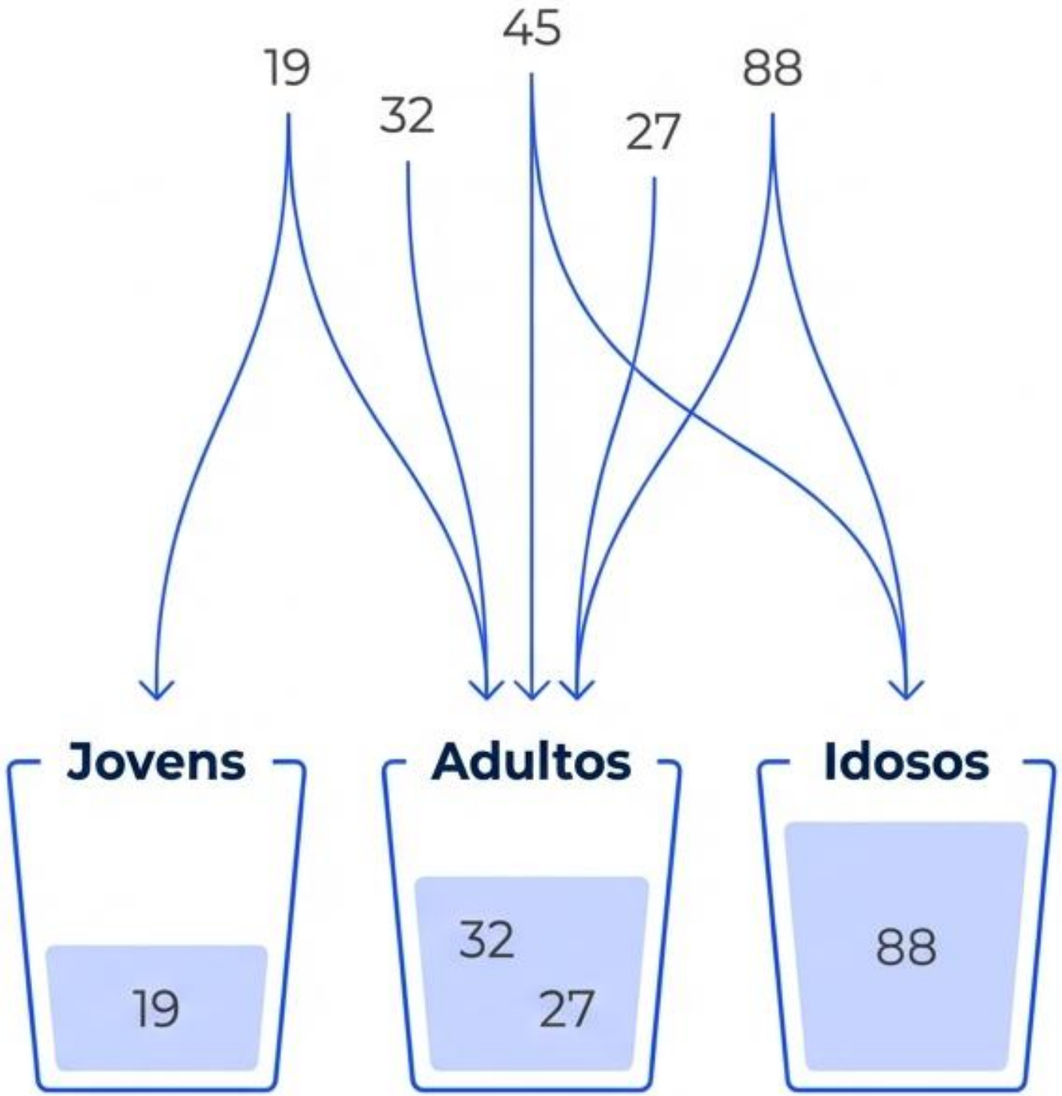

A Função pd.cut: Estruturação de Intervalos Absolutos

- Segmentação de dados baseada em limites matemáticos predefinidos.
- Definição exata dos compartimentos de corte através do parâmetro bins.
- Nomeação semântica das faixas geradas utilizando o parâmetro labels.

```
pd.cut(df['idades'], bins=[18, 25, 60], labels=['Jovem', 'Adulto'])
```

Check de Aprendizado: cut vs qcut

- Avaliação estratégica do cenário de negócios para escolha da função.

Situação A

Exige regras estáticas e cortes matemáticos inegociáveis.

Exemplo: Notas 0-10 -> Reprovado/Aprovado

Situação B

Exige distribuição populacional rigorosamente igualitária.

Exemplo: Classes de Poder Aquisitivo A/B/C com o mesmo volume de clientes

Laboratório PBL 09: O Criador de Segmentos

1

Carga

Execução de leitura e extração da base de dados de salários contínuos.

2

Cut

Aplicação de limites absolutos para segmentação de faixas via pd.cut.

3

Avaliação

Comprovação estatística do desbalanceamento utilizando .value_counts().

4

Qcut

Rebalanceamento arquitetural em quartis exatos utilizando pd.qcut(q=4).

REBALANCEAMENTO ARQUITETURAL EM QUARTIS EXATOS

com pd.qcut(q=4)

ESTADO INICIAL (DESBALANCEADO)

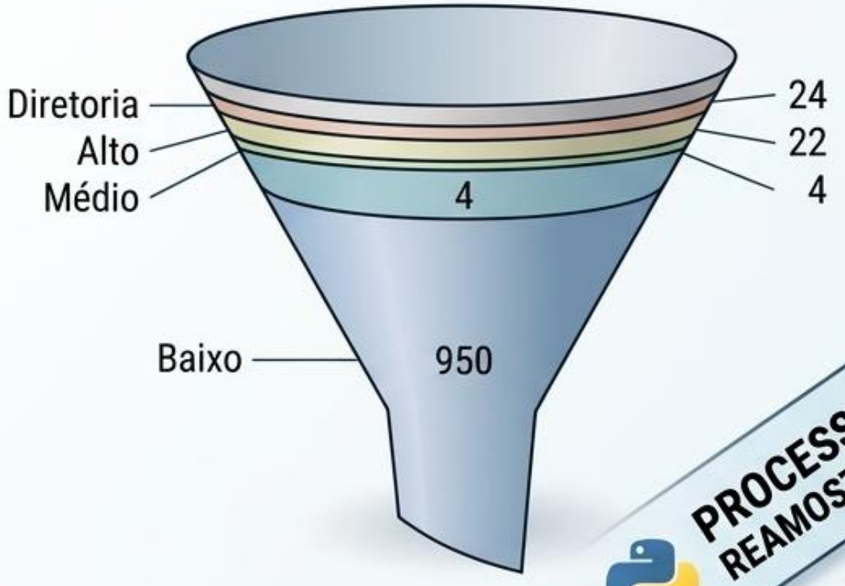

FAIXA SALARIAL	CONTAGEM
Baixo	950
Diretoria	24
Alto	22
Médio	4

TOTAL = 1000 OBS.

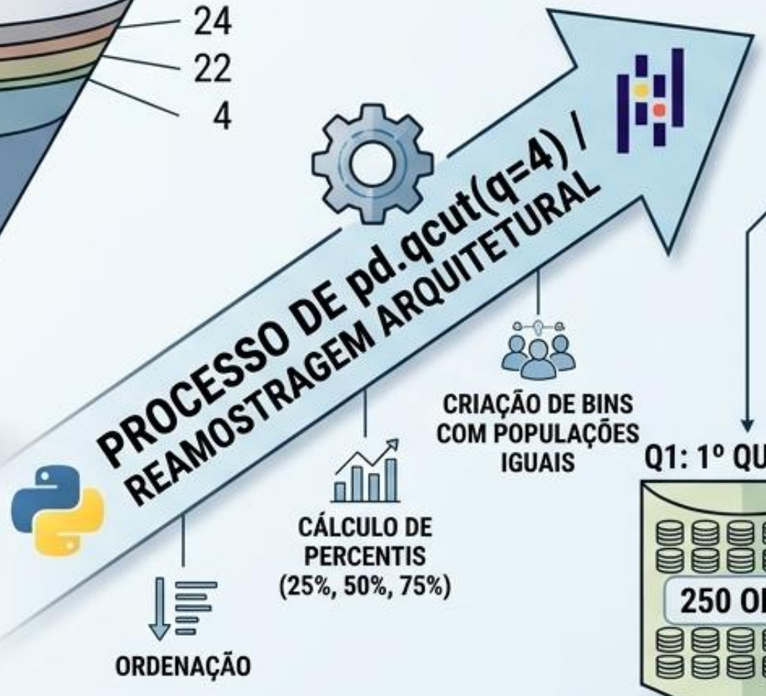

ESTADO FINAL (BALANCEADO POR Q-CUT)

CADA QUARTIL TEM EXATAMENTE 250 OBSERVAÇÕES (25% DE 1000)

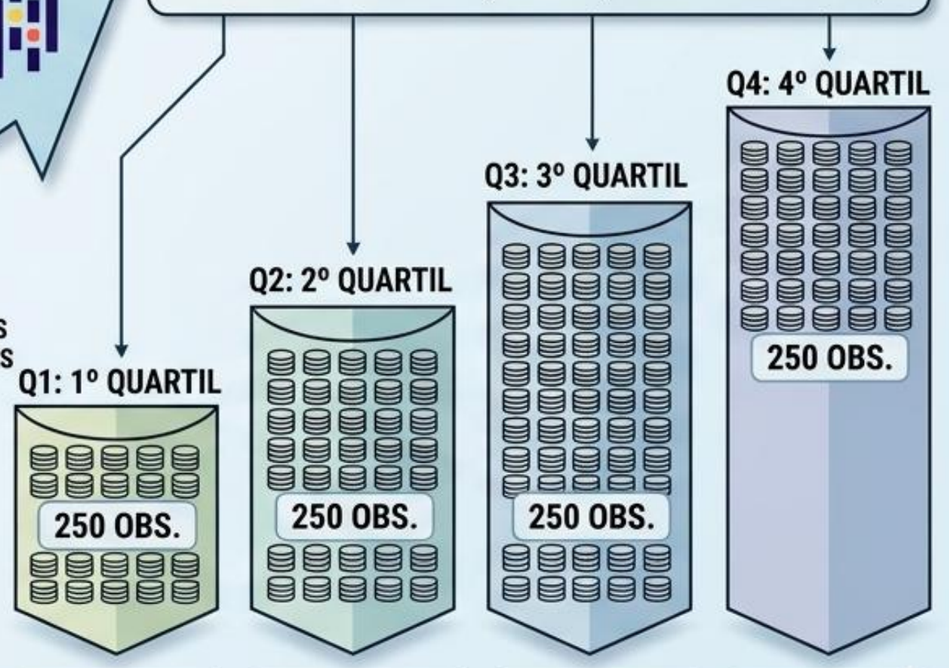

Q1: Faixa mais Baixa

Q2: Faixa Baixa-Média

Q3: Faixa Média-Alta

Q4: Faixa mais Alta

Versionamento, Entrega Semanal e Próximos Passos

- Finalização da frente de manipulação categórica e discretização de dados.
- Validação e commit duplo dos laboratórios 07 (Encoders) e 09 (Binning).
- Próxima fase da jornada analítica: Feature Engineering Temporal.

```
> git add lab_07_encoders.ipynb
lab_09_binning.ipynb
> git commit -m 'feat: encoders avancados e
segmentacao qcut'
> git push origin main
```

Next Steps

→ **Aula 10: Sinais Ocultos do Tempo**

Dúvidas?

CRIATIVIDADE
INOVAÇÃO
¡DEIA!
COMAMUNIDADE
CRIATIVIDADE
BRAINSTORM
INOVAÇÃO

ibmec

A direção do amanhã.

/ibmec