Extração e Preparação de Dados

Aula 11 – Detecção de Outliers

ibmec

Quem sou eu?

Professor: Luís Aramis dos Reis Pinheiro.

- **Doutorado e Mestrado** em **Ciências Mecânicas** – **UnB** – **CAPES 7**
- **Graduação** em Licenciatura em Física – **UNIFAP**

luis.pinheiro@professores.ibemec.edu.br

(96) 99907-5819

@l_aramis

Detecção e Tratamento de Outliers

- Estatística Clássica e Limites Univariados
- Disciplina: Extração e Preparação de Dados (IBM8915)
- Data: 19/03 (Quinta-feira)

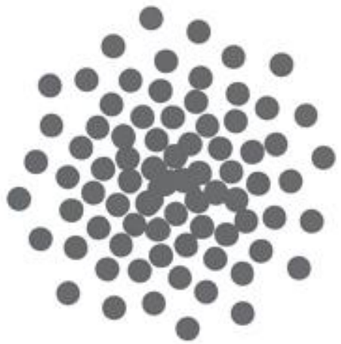

O Paradigma do Outlier

- **A sensibilidade** das métricas clássicas (Média vs. Mediana).
- **O Efeito Elon Musk**: Uma única observação extrema corrompe a realidade estatística.
- **O objetivo do tratamento** não é manipular, mas proteger o modelo preditivo.

Cenário A: Trabalhadores Comuns

Média: R$ 3.000

Cenário B: + Elon Musk

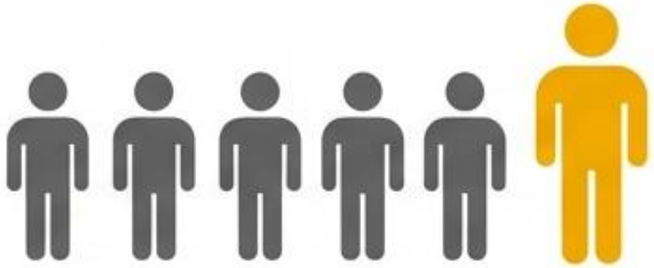

Média: R$ 1.000.000+

O Raio-X da Distribuição (Boxplot)

- A Ferramenta: Representação visual definitiva para discrepâncias.
- A Mediana no Comando: A caixa central foca onde estão 50% dos seus dados reais.
- As ‘Cercas’: Hastes (bigodes) definem o limite do aceitável.
- A Anomalia: Tudo que ultrapassa as cercas é estatisticamente anômalo.

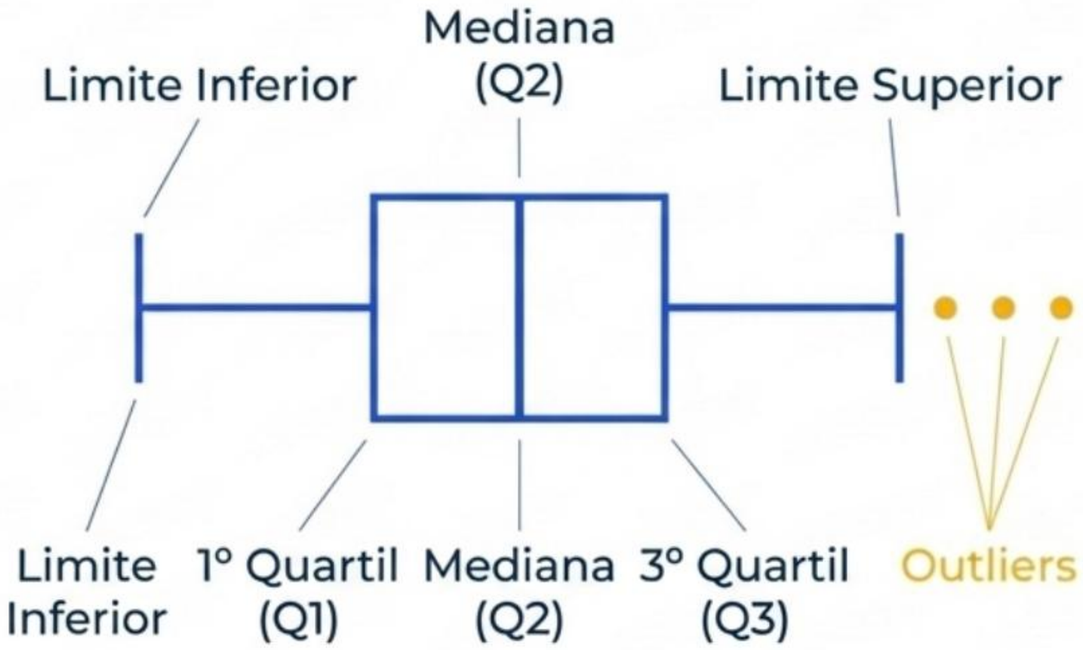

O Cálculo Univariado (IQR)

- **Q1 (1º Quartil):** A marca dos 25% dos dados (.quantile(0.25)).
- **Q3 (3º Quartil):** A marca dos 75% dos dados (.quantile(0.75)).
- **A Fórmula:** IQR = Q3 – Q1 (Intervalo Interquartil).
- **O Propósito:** Medir a dispersão ignorando as caudas extremas.

Definindo as Cercas Estatísticas

- A regra de 1.5x do IQR define a tolerância do modelo.
- Limite Inferior: Q1 - (1.5 * IQR)
- Limite Superior: Q3 + (1.5 * IQR)
- A Regra: Valores fora deste espectro exigem intervenção cirúrgica.

Limite Inferior = Q1 - (1.5 * IQR)

Limite Superior = Q3 + (1.5 * IQR)

Isolando Anomalias no Pandas

- Traduzindo a estatística para código Python.
- Criação de Máscaras Booleanas (Filtros lógicos).
- Ação: Fatiar o DataFrame original usando a máscara para auditar as falhas.

```
mascara = (df['col'] < lim_inf) | (df['col'] > lim_sup)

anomalias_isoladas = df[mascara]
```

Check de Aprendizado (O Dilema da Remoção)

- Cenário: Você isolou 15% do seu dataset como Outliers na coluna de Salários.
- Ação: Você decide excluir todas essas linhas (df = df[~mascara]).
- Reflexão: Deletar 15% das linhas é inofensivo?

- **Pergunta:** Qual o **grave efeito colateral e irreversível** para o Machine Learning?

O Dilema da Exclusão: Retenção vs. Distorção

- A exclusão tradicional destrói linhas inteiras e colunas perfeitamente válidas.
- Perda catastrófica de até 15% do histórico comportamental do modelo.
- A necessidade técnica de neutralizar o peso do outlier sem deletar o registro.
- Transição da amputação de dados para o amassamento de extremos.

Amputação vs. Massaging

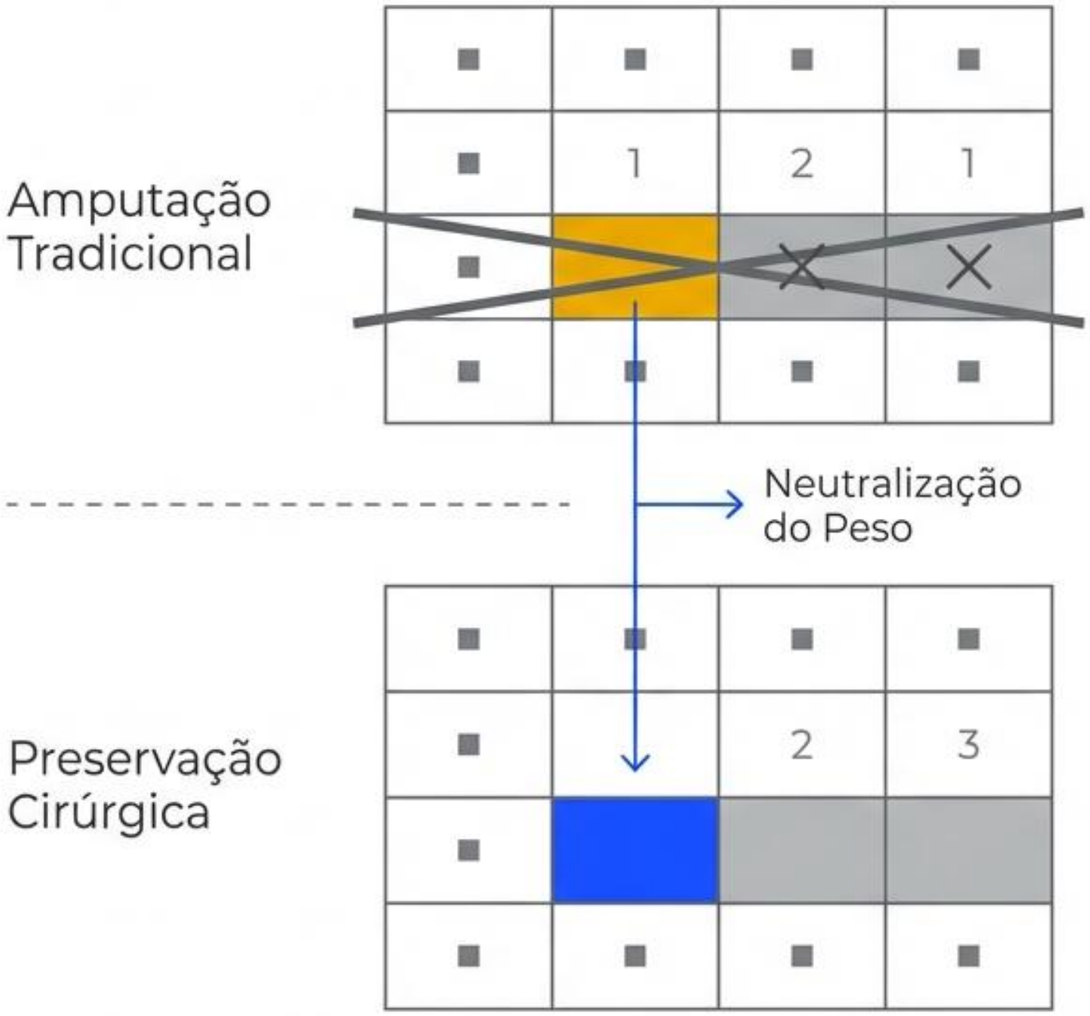

A Cirurgia de Clipping (Winsorization)

- Winsorization: Técnica estatística que limita valores extremos a um teto/piso.
- O método .clip() do Pandas substitui valores além do limite pelo próprio valor do limite.
- Preservação integral do formato e do histórico do DataFrame.
- Redução drástica da variância sem a perda de data points cruciais.

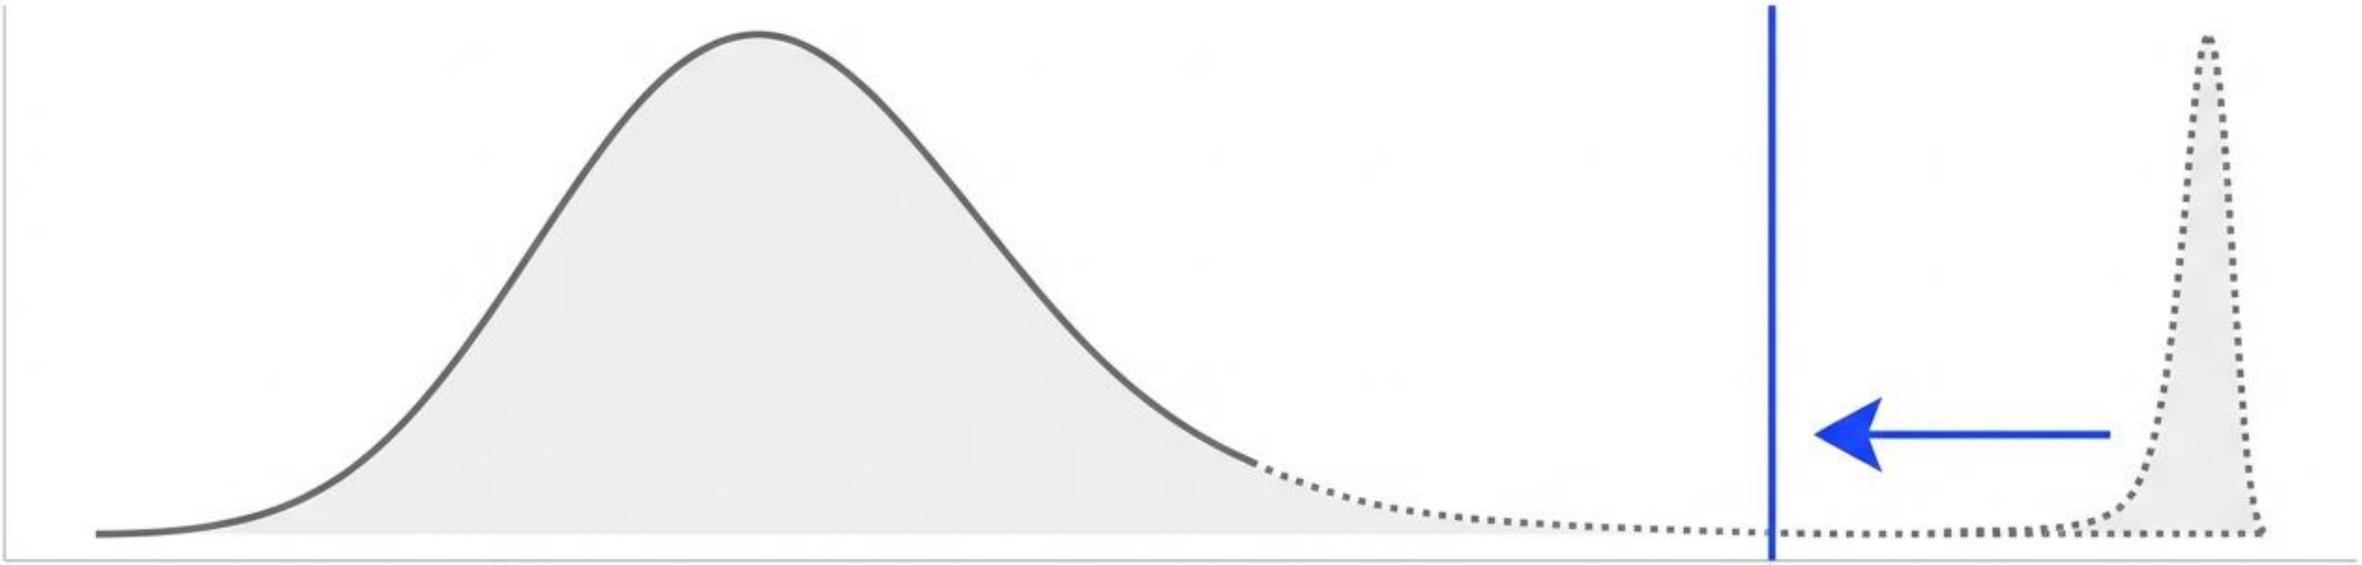

```
df['salario'].clip(upper=limite_calculado)
```

O Paradigma Multivariado das Anomalias

- Limitações da análise univariada: avaliar uma única dimensão esconde correlações.
- O problema da Anomalia de Contexto em matrizes complexas.
- Interseções impossíveis: valores individualmente normais, mas conjuntamente anômalos.
- A necessidade de escalar a auditoria utilizando Inteligência Artificial.

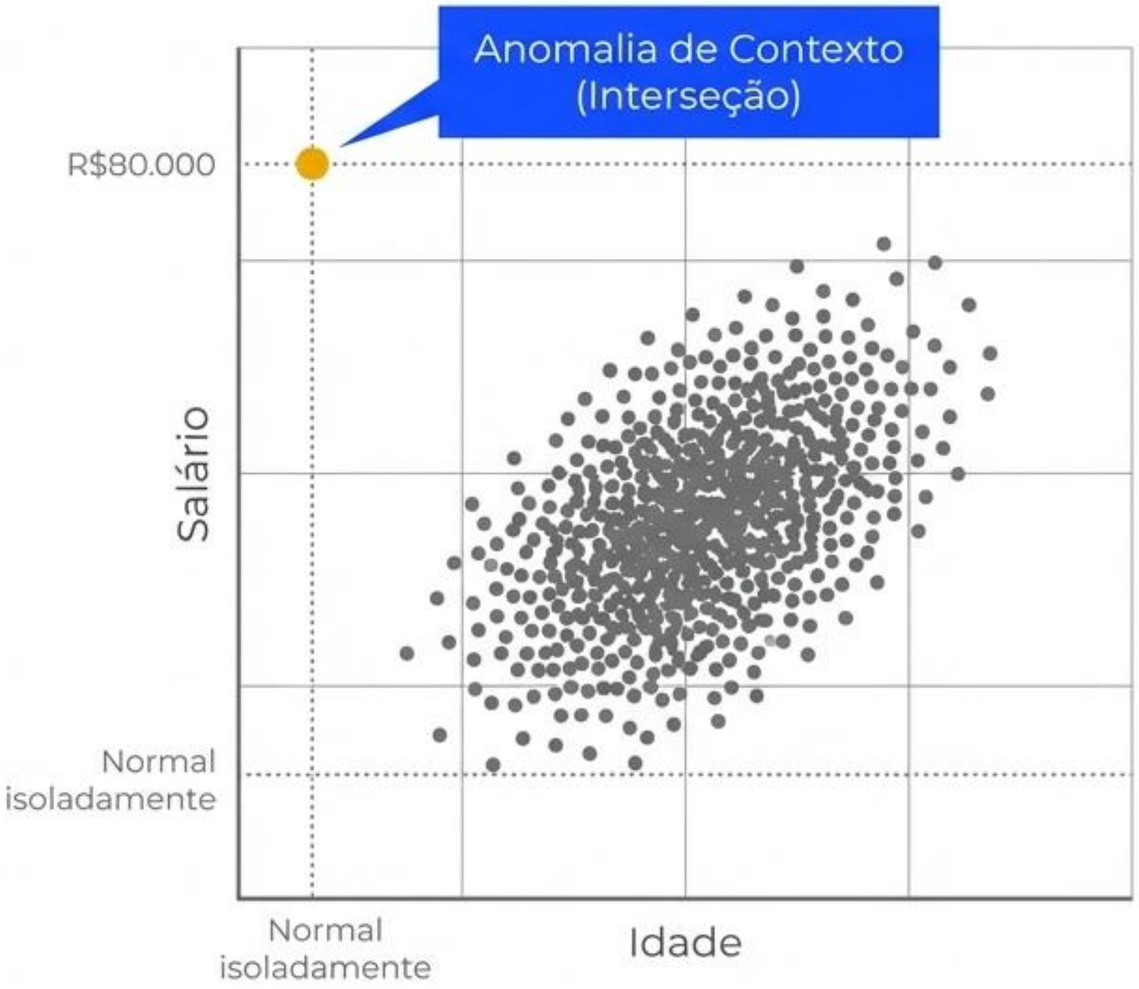

Machine Learning: O Isolation Forest

- Transição analítica: Do Pandas descritivo para o Scikit-Learn preditivo.
- Algoritmo não-supervisionado baseado em partições de Árvores de Decisão.
- Princípio do Isolamento: Anomalias exigem menos cortes matemáticos para serem separadas.
- O hiperparâmetro contamination define a proporção esperada de ruído.

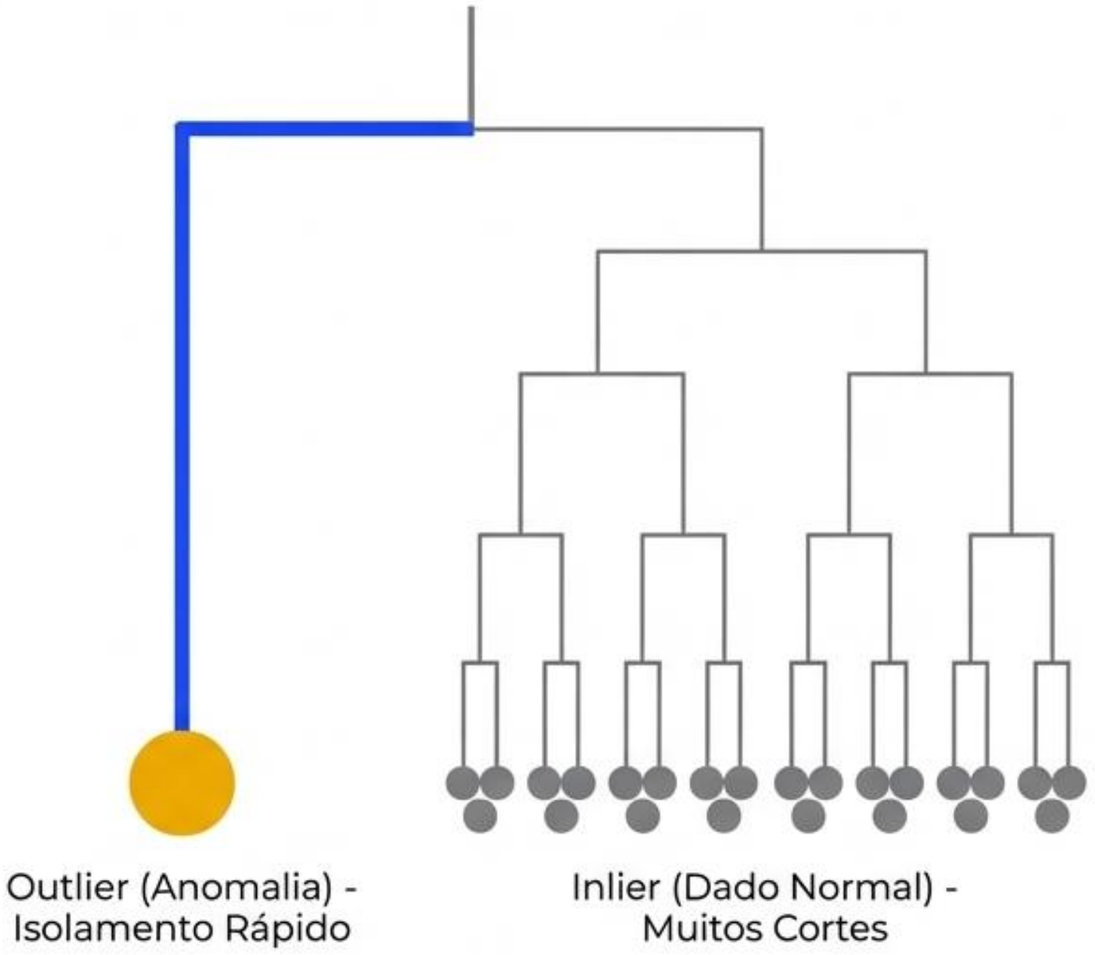

O OUTLIER (ANOMALIA) - ISOLAMENTO RÁPIDO

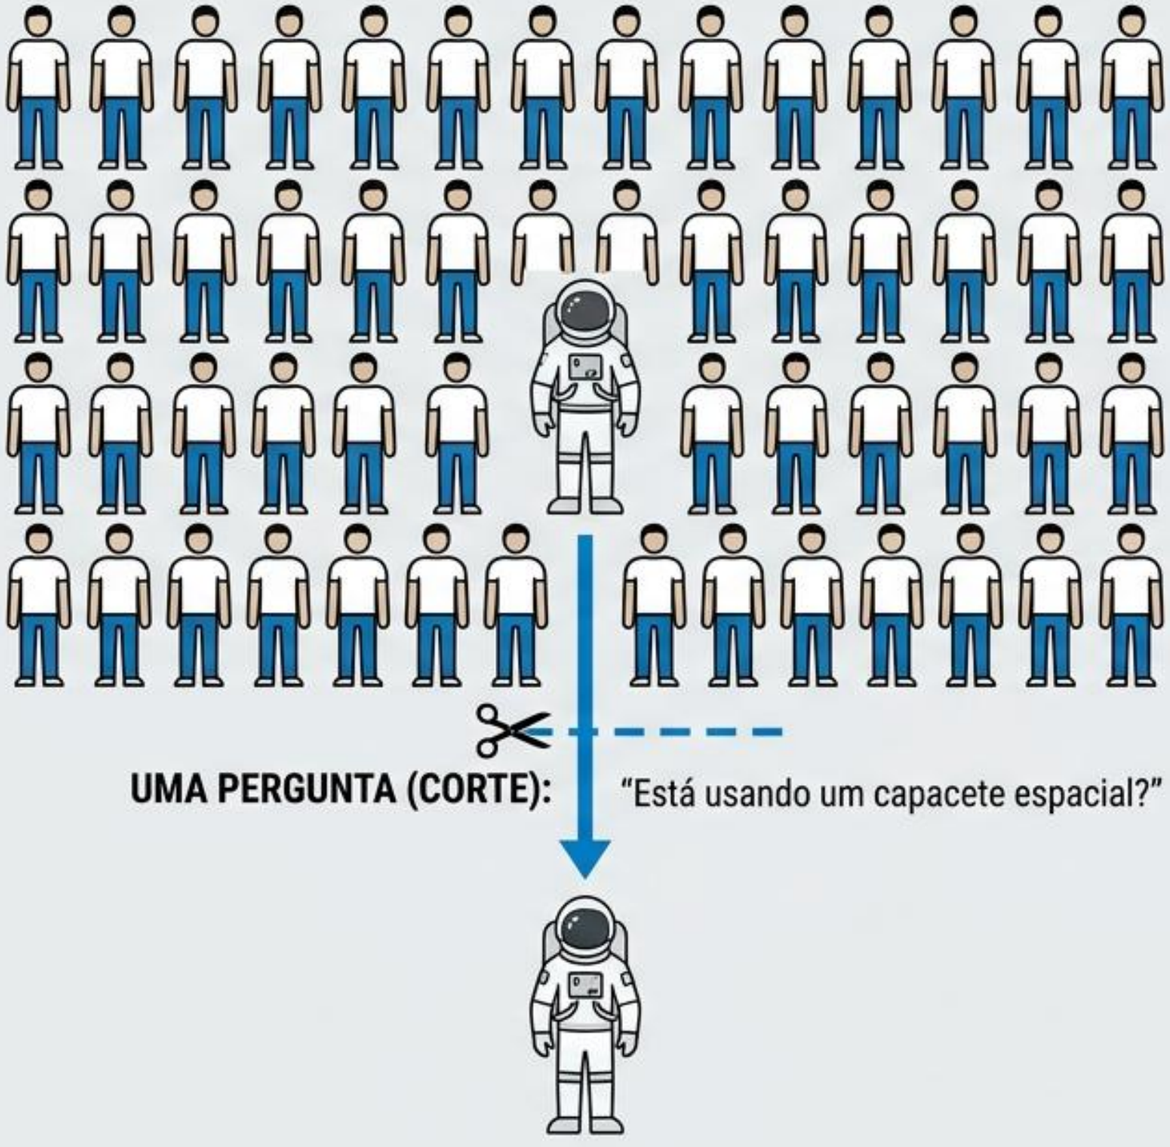

Isolado Rápida e Facilmente

OS INLIERS (DADOS NORMAIS) - ISOLAMENTO COMPLEXO

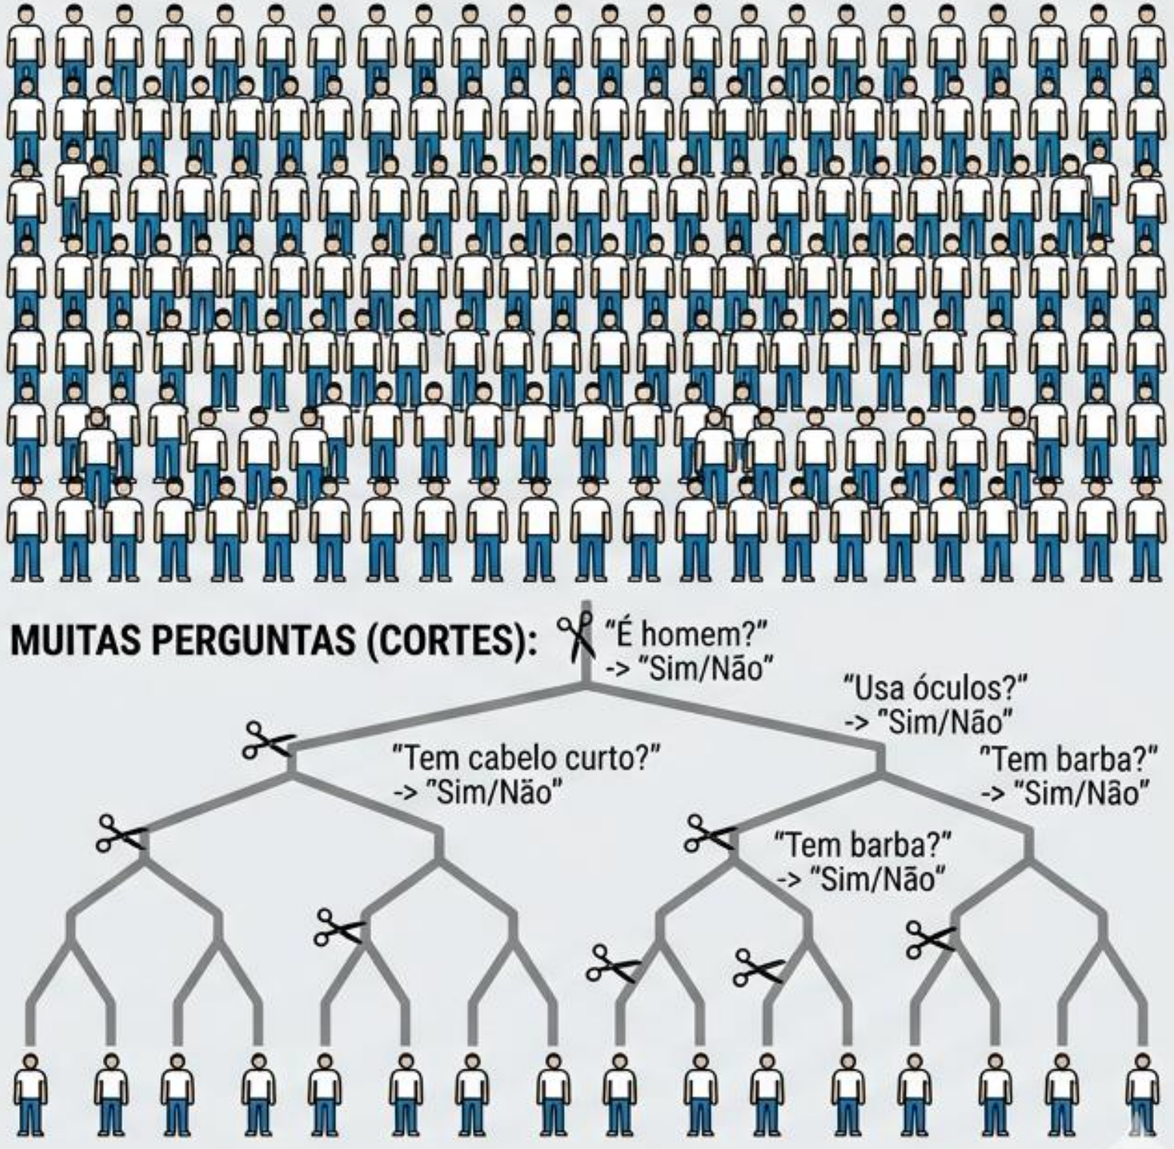

Isolar requer muitas etapas e esforço

A API do Scikit-Learn e Indexação Booleana

- Instanciação e treinamento simultâneo usando .fit_predict().
- O padrão de saída do modelo para detecção de anomalias:
- 1 = Inlier (Observação normal e pertencente à distribuição).
- -1 = Outlier (Anomalia detectada pelo algoritmo).
- Filtragem avançada via máscara booleana para auditoria cirúrgica.

```
modelo = IsolationForest(contamination=0.05)
df['Outlier_ML'] = modelo.fit_predict(df_numerico)
fraudes = df[df['Outlier_ML'] == -1]
```

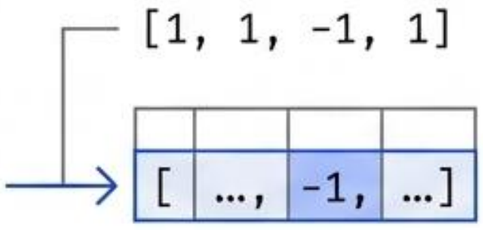

O GERENTE DA BALADA E O PARÂMETRO 'CONTAMINATION'

CONTRATANDO O SEGURANÇA (O ALGORITMO)

A festa (dados) está prestes a começar.
Você contrata um algoritmo para a porta.

A festa (dados) está prestes a começar.
Você contrata um algoritmo para a porta.

DEFININDO O LIMITE: CONTAMINATION = 0.05 (5%)

"Fique de olho e barre os 5% mais estranhos".

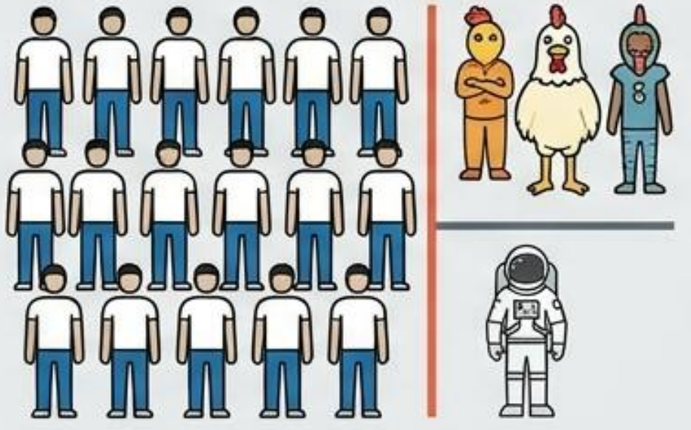

O RESULTADO NA PORTA: ISOLAMENTO DE ANOMALIAS

ENTRADA PERMITIDA (INLIERS)

95% aceitos como normais.
O clube funciona sem problemas.

ZONA DE ISOLAMENTO (OUTLIERS)

5% barrados e isolados como anomalias.
"Baderneiros" detidos.

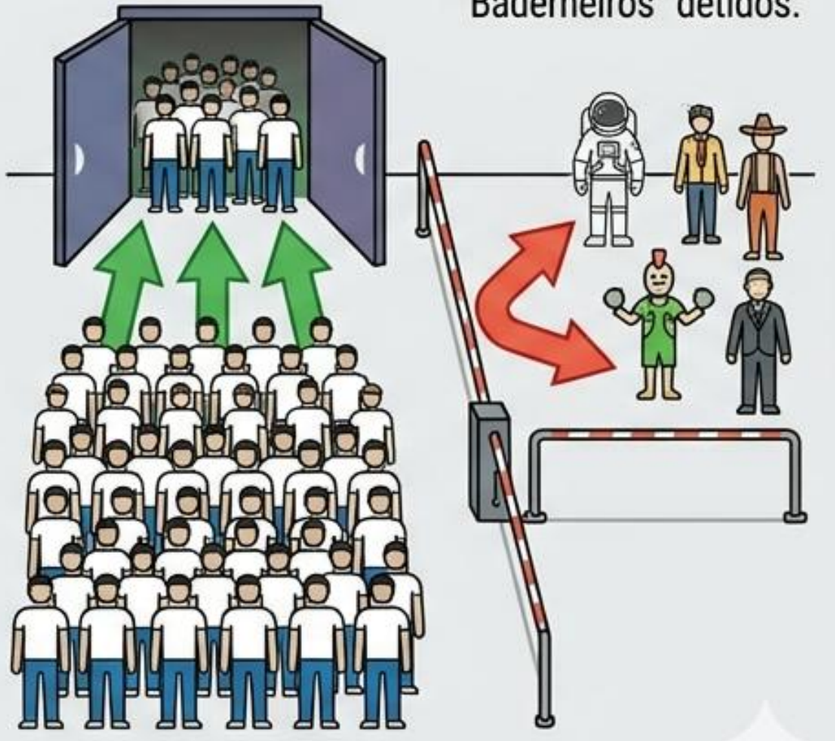

O algoritmo usa o limite para separar dados.

Hands-on: Laboratório PBL (Lab 10)

- Abertura do ambiente de desenvolvimento: lab_10_outliers.ipynb.
- Regra de Negócio: Proibido o uso de dropna() para o tratamento de extremos.
- **Missão 1**: Aplicar .clip() limitando distorções nas variáveis univariadas.
- **Missão 2**: Instanciar a Isolation Forest e capturar anomalias multidimensionais.

Passo 1: Clipping Univariado

Passo 2: Auditoria Multidimensional

O Fim do Tratamento de Variáveis

- O Grande Marco: Dados livres de nulos, enriquecidos e sem outliers severos.
- Entregável da semana: Commit do lab_10_outliers.ipynb no GitHub.
- Encerramento da fase descritiva da disciplina de Extração e Preparação.
- Próximo Capítulo: Feature Scaling (Padronização) e balanceamento de classes (SMOTE).

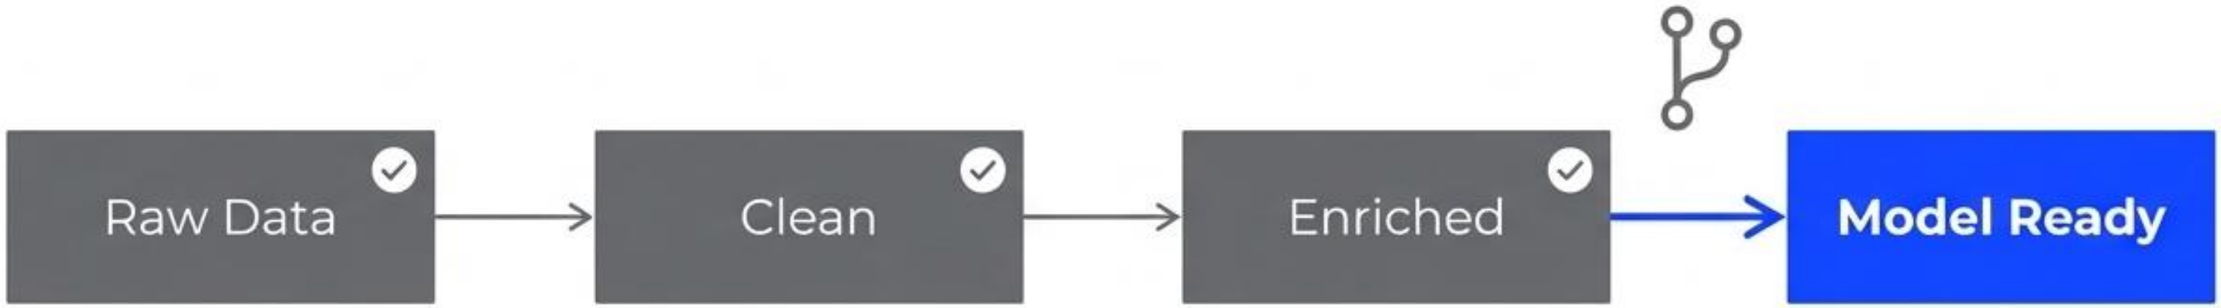

Dúvidas?

CRIATIVIDADE
INOVAÇÃO
¡DEIA!
COMAMUNIDADE
CRIATIVIDADE
BRAINSTORM
INOVAÇÃO

ibmec

A direção do amanhã.

/ibmec